

Aplicações:

Incluir as distribuições discretas: distribuição degenerada + distribuição uniforme + distribuição multinomial

Incluir as distribuições contínuas: uniforme + exponenciais + triangulares

Distribuição de Bernoulli:

Jogar a moeda, só temos duas possibilidades, cara ou coroa. A v.a. será definida como cara = 1 e coroa = 0. Qualquer jogo com apenas duas respostas, sim = 1 e não = 0, segue uma distribuição de Bernoulli. Se a probabilidade de SIM é p , a de Não será $q = 1 - p$ e a função densidade de probabilidade é dada por: $f(x) = q\delta(x) + p\delta(x-1)$. A função distribuição de probabilidade acumulada vale:

$$F(x) = \begin{cases} 0 & x < 0 \\ q & 0 \leq x < 1 \\ 1 & x \geq 1 \end{cases}$$

A função geradora dos momentos é dada por: $M(t) = \int_{-\infty}^{+\infty} [q\delta(x) + p\delta(x-1)] e^{xt} dx = q + pe^t$. A

função característica $\varphi(t) = q + pe^{it}$.

Momentos: $M_k = \int_{-\infty}^{+\infty} [q\delta(x) + p\delta(x-1)] x^k dx = q0^k + p1^k$ logo $M_k = p \quad \forall k$, então $\mu = p$.

Momentos centrados: $e^{-\mu t} M(t) = e^{-pt} [q + pe^t] = qe^{-pt} + pe^{(1-p)t} = qe^{-pt} + pe^{qt}$.

Agora $m_k = \frac{d^k}{dt^k} [qe^{-pt} + pe^{qt}] = q(-p)^k e^{-pt} + pq^k e^{qt} \Big|_{t=0}$, ou seja, $m_k = pq^k + (-1)^k qp^k$ ou ainda

$$m_k = pq \left[(1-p)^{k-1} - (-p)^{k-1} \right].$$

Casos particulares:

$$1. \quad m_1 = pq - qp = 0;$$

$$2. \quad m_2 = pq[(1-p) + p] = pq;$$

$$3. \quad m_3 = pq[(1-p)^2 - p^2] = pq[1-2p+p^2-p^2] = pq(1-2p);$$

$$4. \quad m_4 = pq[(1-p)^3 - p^3] = pq[1-3p+3p^2-p^3+p^3] = pq[1-3p(1-p)] = pq[1-3pq].$$

Cumulantes:

$$\ln \varphi(t) = \ln[1 + p(e^{it} - 1)], \quad \text{então} \quad \frac{d}{dt} \ln \varphi(t) = \frac{ipe^{it}}{1 + p(e^{it} - 1)} = \frac{ip}{e^{-it} + p - pe^{-it}} = \frac{ip}{p + (1-p)e^{-it}}$$

logo:

$$1. \quad \frac{d}{dt} \ln \varphi(t) = ip(p + qe^{-it})^{-1}. \text{ Logo } c_1 = -i \frac{d}{dt} \ln \varphi(t) \Big|_{t=0} = p$$

$$2. \quad \frac{d^2}{dt^2} \ln \varphi(t) = i^2 pq [e^{-it} (p + qe^{-it})^{-2}], \text{ logo } \sigma^2 = c_2 = (-i)^2 \frac{d^2}{dt^2} \ln \varphi(t) = pq.$$

$$3. \quad \frac{d^3}{dt^3} \ln \varphi(t) = i^3 pq [2qe^{-2it} (p + qe^{-it})^{-3} - e^{-it} (p + qe^{-it})^{-2}] = -i^3 pqe^{-it} (p - qe^{-it}) (p + qe^{-it})^{-3}$$

$$\text{logo, } m_3 = c_3 = (-i)^3 \frac{d^3}{dt^3} \ln \varphi(t) \Big|_{t=0} = pq(q - p).$$

$$4. \quad \frac{d^4}{dt^4} \ln \varphi(t) = i^4 pqe^{-it} [(p - 2qe^{-it})(p + qe^{-it}) + 3qe^{-it}(qe^{-it} - p)](p + qe^{-it})^{-4}. \quad \text{Após}$$

$$\text{alguma álgebra temos } \frac{d^4}{dt^4} \ln \varphi(t) = i^4 pqe^{-it} [p^2 - 4pqe^{-it} + q^2e^{-2it}](p + qe^{-it})^{-4}, \text{ logo}$$

$$c_4 = (-i)^4 \frac{d^4}{dt^4} \ln \varphi(t) \Big|_{t=0} = pq[p^2 - 4pq + q^2] \text{ ou } c_4 = pq[1 - 6pq].$$

Distribuição Binomial:

Vamos jogar a moeda n vezes de forma independente. Nesse caso a v.a. soma são i.i.d., e a função característica vale: $\varphi_{Bin}(t) = \varphi_{Bern}^n(t) = [q + pe^{it}]^n$. Sabendo a φ queremos a $f(z)$ dada por

$$f(z) = FT^{-1}[\varphi(t)] = \frac{1}{2\pi} \int_{-\infty}^{+\infty} [q + pe^{it}]^n e^{-itz} dt. \text{ Expandindo em binômio de Newton temos:}$$

$$f(z) = \sum_{k=0}^n \binom{n}{k} q^{n-k} p^k \left[\frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{i(k-z)t} dt \right] = \sum_{k=0}^n \binom{n}{k} q^{n-k} p^k \delta(z-k)$$

Aqui vale a acumulação dos cumulantes $c_{k Bin} = n c_{k Bern}$, então $\mu = np$, $\sigma^2 = npq$, $c_3 = npq(q-p)$ e $c_4 = npq[1-6pq]$.

Distribuição de Poisson:

Essa distribuição é um caso limite da binomial quando $n \rightarrow \infty$, mas $p \rightarrow 0$ de tal forma que o produto

$np = \lambda$ é constante. Agora $\varphi_{Bin}(t) = [1 - p + pe^{it}]^n = \left[1 + \frac{\lambda(e^{it} - 1)}{n} \right]^n$. Nesse ponto usamos o fato de

que $\lim_{n \rightarrow \infty} \left[1 + \frac{x}{n} \right]^n = e^x$ para achar $\varphi_{Poisson}(t) = e^{\lambda(e^{it} - 1)}$. Agora queremos a fdp:

$$f(z) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{\lambda(e^{it} - 1)} e^{-itz} dt = \frac{e^{-\lambda}}{2\pi} \int_{-\infty}^{+\infty} e^{\lambda e^{it}} e^{-itz} dt = \sum_{k=0}^{\infty} e^{-\lambda} \frac{\lambda^k}{k!} \left[\frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{ikt} e^{-itz} dt \right] = \sum_{k=0}^{\infty} e^{-\lambda} \frac{\lambda^k}{k!} \delta(z-k)$$

$$f_{Poisson}(z) = \sum_{k=0}^{\infty} \frac{e^{-\lambda} \lambda^k}{k!} \delta(z-k).$$

Uma expressão para $F_{Poisson}(z)$.

$$F_{Poisson}(z) = \int_{-\infty}^z f_{Poisson}(x) dx = \sum_{k=0}^{\infty} \frac{e^{-\lambda} \lambda^k}{k!} \int_{-\infty}^z \delta(x-k) dx = e^{-\lambda} \sum_{k=0}^{\text{int}(z)} \frac{\lambda^k}{k!}$$

$$\text{Então } F_{Poisson}(z) = e^{-\lambda} \sum_{k=0}^{\text{int}(z)} \frac{\lambda^k}{k!}.$$

Cumulantes: $\ln \varphi_{Poisson}(t) = \ln \left[e^{\lambda(e^{it} - 1)} \right] = \lambda(e^{it} - 1) = \lambda \sum_{k=1}^{\infty} \frac{i^k t^k}{k!}$, portanto todos os cumulantes valem

λ , daí $\mu = \lambda$, $\sigma^2 = \lambda$, $m_3 = \lambda$ e $m_4 = \lambda + 3\lambda^2$, a skewness vale $\alpha_3 = \frac{1}{\sqrt{\lambda}} > 0$, skewed to the right, e

a curtose $k = \frac{1}{\lambda}$, sempre leptocúrtica. Se $\lambda \rightarrow \infty$ então a skewness e curtose tendem a zero.

Distribuição Normal:

Vamos fazer o limite de n tendendo a infinito na distribuição binomial e usar o truque do logaritmo.

Nesse caso:

$$\ln \varphi_{Bin}(t) = \varphi_{Bern}^n(t) = n \ln \left[q + p e^{it} \right] = n \ln \left[q + p + ipt - p \frac{t^2}{2} + \dots \right] = n \ln \left[1 + ipt - p \frac{t^2}{2} + \dots \right]. \quad \text{Mas}$$

já sabemos que $\ln(1+x) = x - \frac{x^2}{2} + \frac{x^3}{3} + \dots = \sum_{k=1}^{\infty} \frac{(-1)^{k-1}}{k} x^k$ e vamos truncar a série na ordem 2.

Chamando $x = ipt - p \frac{t^2}{2}$ temos:

$$\ln \varphi_{Bin}(t) = n \left[ipt - p \frac{t^2}{2} + \left(ipt - p \frac{t^2}{2} \right)^2 \right] = n \left[ipt - p \frac{t^2}{2} - p^2 \frac{t^2}{2} + \dots \right] = n \left[ipt - p(1-p) \frac{t^2}{2} + \dots \right]$$

Logo $\lim_{n \rightarrow \infty} [\ln \varphi_{Bin}(t)] = inpt - \frac{npqt^2}{2} + \dots$ e essa é a distribuição normal, cuja função característica

vale: $\varphi_{Normal}(t) = e^{i\mu t - \frac{\sigma^2 t^2}{2}}$. Note que, nesse caso, só existem dois cumulantes, pois

$\ln[\varphi_{Normal}(t)] = i\mu t - \frac{\sigma^2 t^2}{2}$, $c_1 = \mu$ e $c_2 = \sigma^2$, todos os outros são nulos. Os momentos centrados

são dados pela função geradora:

$$e^{-i\mu t} e^{i\mu t - \frac{\sigma^2 t^2}{2}} = e^{\frac{\sigma^2 t^2}{2}} = \sum_{k=0}^{\infty} \frac{\left(-\frac{\sigma^2 t^2}{2} \right)^k}{k!} = \sum_{k=0}^{\infty} \frac{(-1)^k \sigma^{2k}}{2^k k!} t^{2k} = \sum_{k=0}^{\infty} \frac{(-1)^k \sigma^{2k} (2k)!}{2^k k!} \frac{t^{2k}}{(2k)!}.$$

Percebe-se que não existem momentos ímpares e que os pares valem

$$\sum_{k=0}^{\infty} (i)^{2k} m_{2k} \frac{t^{2k}}{(2k)!} = \sum_{k=0}^{\infty} (-1)^k m_{2k} \frac{t^{2k}}{(2k)!}. \text{ Comparando extraímos } m_{2k} = \frac{(2k)!}{2^k k!} \sigma^{2k}. \text{ Podemos}$$

reescrever esse resultado em termos dos fatoriais duplos $z!! = z(z-2)(z-4)\dots$. Notando que

$$(2k)!! = (2k)(2k-2)(2k-4)\dots 2 = 2 \times 2 \times \dots \times 2 \times k(k-1)(k-2)\dots 1 = 2^k k! \text{ e, além disso, que:}$$

$$(2k)! = (2k)(2k-1)(2k-2)(2k-3)\dots 2 \times 1 = [(2k)(2k-2)\dots 2][(2k-1)(2k-3)\dots 1]$$

$$\text{logo } (2k)! = (2k)!!(2k-1)!!, \text{ substituindo } m_{2k} = \frac{(2k)!!(2k-1)!!}{(2k)!!} \sigma^{2k} \text{ chegamos na expressão mais}$$

simples $m_{2k} = (2k-1)!! \sigma^{2k}$. Então vemos que $m_2 = \sigma^2$; $m_4 = (3)!! \sigma^4 = 3\sigma^4$; $m_6 = (5)!! \sigma^6 = 15\sigma^6$ e assim por diante.

Falta a função densidade de probabilidade: $f(z) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{i\mu t - \frac{\sigma^2 t^2}{2}} e^{-itz} dt$. O truque aqui é completar

$$\text{quadrado no expoente } e^{-\frac{\sigma^2 t^2}{2} + i\mu t - itz} = e^{-\frac{\sigma^2 t^2}{2} - it(z-\mu)} = e^{-\frac{\sigma^2}{2} \left[t^2 + 2i \frac{(z-\mu)}{\sigma^2} t - \frac{(z-\mu)^2}{\sigma^4} + \frac{(z-\mu)^2}{\sigma^4} \right]}, \text{ obtendo}$$

$$e^{-\frac{\sigma^2 t^2}{2} + i\mu t - itz} = e^{-\frac{(z-\mu)^2}{2\sigma^2}} e^{-\frac{\sigma^2}{2} \left(t + i \frac{z-\mu}{\sigma^2} \right)^2}.$$

Substituindo de volta na integral temos:

$$f(z) = \frac{e^{-\frac{(z-\mu)^2}{2\sigma^2}}}{2\pi} \frac{\sqrt{2}}{\sigma} \int_{-\infty}^{+\infty} e^{-\frac{\sigma^2}{2} \left(t + i \frac{z-\mu}{\sigma^2} \right)^2} d\left(\frac{\sigma t}{\sqrt{2}} \right) = \frac{e^{-\frac{(z-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \int_{-\infty}^{+\infty} e^{-u^2} du = \frac{e^{-\frac{(z-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \sqrt{\pi}$$

Finalmente obtemos a função densidade de probabilidade da distribuição Normal:

$$N(x; \mu, \sigma) = \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}$$

A Normal Padrão tem esperança nula e variância unitária dada por $NP(x) = \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi}}$. A Normal padrão

cumulativa é definida como $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$. Note que é sempre possível escrever o resultado

de uma normal cumulativa em termos da $\Phi(x)$ por uma mudança de variável. Se queremos a função

distribuição de probabilidade cumulativa de uma normal com μ e σ , ou seja:

$$F_{Normal}(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(x-\mu)^2}{2\sigma^2}} d\left(\frac{x}{\sigma}\right)$$

a $F_{Normal}(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{(x-\mu)/\sigma} e^{-\frac{t^2}{2}} dt = \Phi\left(\frac{x-\mu}{\sigma}\right)$. Por isso as tabelas da normal são sempre feitas para a

normal padrão usando como argumento o desvio da esperança medido em desvios padrão $z = \frac{x-\mu}{\sigma}$.

Distribuição Log-Normal.

A distribuição Log-Normal é obtida da Normal através da mudança de variável $y = e^x$. A regra á

mudança de variável é dada por $f(y) = \sum \frac{f[g^{-1}(y)]}{\left|\frac{dy}{dx}\right|}$, com a somatória sobre todos os x 's possíveis

para as raízes da equação $g(x) = y$, ou, $x = g^{-1}(y)$. Neste caso a função é biunívoca e só existe uma

raiz dada por $x = \ln y$, $y \in [0, +\infty)$. Vamos precisar da derivada $\frac{dy}{dx} = e^x = y$. Logo:

$$LogN[y; \mu, \sigma^2] = \frac{e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma y}$$

A log-Normal como uma aproximação da normal:

Vamos reescrever a log-normal como $LogN = \frac{e^{-\frac{(\ln y - \ln y_o)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma y} = \frac{e^{-\frac{\left[\ln\left(\frac{y}{y_o}\right)\right]^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma y} =$, $y_o > 0$, e ver o que

acontece para $y = y_o + \delta y$ com $|\delta y| \ll y_o$.

Neste caso $\ln y = \ln(y_o + \delta y) = \ln\left[y_o\left(1 + \frac{\delta y}{y_o}\right)\right] = \ln y_o + \ln\left(1 + \frac{\delta y}{y_o}\right)$ e o termo no expoente é

aproximado por $(\ln y - \ln y_o) = \ln\left(1 + \frac{\delta y}{y_o}\right) \cong \frac{\delta y}{y_o}$. No denominador simplesmente fazemos $y = y_o$ e

vemos que $LogN = \frac{e^{-\frac{\delta y^2}{2\sigma^2 y_o^2}}}{\sqrt{2\pi}\sigma y_o}$ é uma normal da variável $\delta y / y_o$. Se fizermos $\sigma_{log N} = \frac{\sigma_N}{y_o}$ teremos

duas curvas muito semelhantes no caso em que $\sigma_N \ll \mu$. Note que se $y \rightarrow 0$ o $\ln y \rightarrow -\infty$ anulando a função. Grandes diferenças, portanto, entre a normal e a log-normal ocorrerão quando a probabilidade de valores de x negativos na normal forem grandes. A figura xx mostra esse comportamento:




Figura xxx. Normal com $x_o = y_o = 100$. (a) $\sigma_N = 10$ e $\sigma_{\log N} = 0,1$; (b) $\sigma_N = 20$ e $\sigma_{\log N} = 0,2$; (c) $\sigma_N = 40$ e $\sigma_{\log N} = 0,4$.

Tanto a função geradora dos momentos quanto a função característica apresentam problemas de

convergência, mas podemos calcular os momentos da Log-Normal $M_n = \int_0^\infty y^n \frac{e^{-\frac{(\ln y - \mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \frac{dy}{y}$ mudando a

variável de integração para $\ln y = x$, $y = e^x$, $\frac{dy}{y} = dx$, quando $y \rightarrow 0$ $x \rightarrow -\infty$ e quando

$y \rightarrow +\infty$ $x \rightarrow +\infty$. Nesse caso: $M_n = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^\infty e^{nx} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$. O truque aqui é completar quadrado

no expoente: $e^{nx} e^{-\frac{(x-\mu)^2}{2\sigma^2}} = e^{-\frac{(x-\mu)^2 - 2\sigma^2 nx}{2\sigma^2}} = e^{-\frac{x^2 - 2\mu x + \mu^2 - 2\sigma^2 nx}{2\sigma^2}} = e^{-\frac{x^2 - 2(\mu + n\sigma^2)x + (\mu + n\sigma^2)^2 - (\mu + n\sigma^2)^2 + \mu^2}{2\sigma^2}}$

continuando $e^{nx} e^{-\frac{(x-\mu)^2}{2\sigma^2}} = e^{-\frac{(x-\mu x - n\sigma^2)^2 - (\mu^2 + 2\mu n\sigma^2 + n^2\sigma^4) + \mu^2}{2\sigma^2}} = e^{\frac{\mu + n^2\sigma^2}{2}} e^{-\frac{(x-\mu x - n\sigma^2)^2}{2\sigma^2}}$. Daí vemos que

$M_n = e^{\frac{\mu + n^2\sigma^2}{2}} \left[\frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^\infty e^{-\frac{(x-\mu x - n\sigma^2)^2}{2\sigma^2}} dx \right]$. A integral entre colchetes vale 1 e temos todos os

momentos de ordem n dados por $M_n = e^{\frac{\mu + n^2\sigma^2}{2}}$. Em particular temos $M_0 = 1$; $M_1 = e^{\frac{\mu + \sigma^2}{2}}$;

$M_2 = e^{2\mu + 2\sigma^2}$; $M_3 = e^{3\mu + \frac{9}{2}\sigma^2}$ e $M_4 = e^{4\mu + 8\sigma^2}$. Podemos calcular os momentos centrados usando

binômio de Newton $m_n = \sum_{k=0}^n \binom{n}{k} (-1)^{n-k} \mu^{n-k} M_k$. Já sabemos que $m_0 = 1$ e $m_1 = 0$. Para a

variância m_2 temos: $m_2 = M_2 - M_1^2$ logo $m_2 = e^{2\mu + 2\sigma^2} - e^{2\mu + \sigma^2} = e^{2\mu + \sigma^2} (e^{\sigma^2} - 1)$,

$V[y] = e^{2\mu+\sigma^2}(e^{\sigma^2} - 1)$ e $\sqrt{V[y]} = e^{\mu+\frac{\sigma^2}{2}}\sqrt{(e^{\sigma^2} - 1)}$. Para o momento centrado de ordem 3 temos

$m_3 = M_3 - 3M_1M_2 + 2M_1^3$ de onde extraímos que

$$m_3 = e^{3\mu+\frac{9}{2}\sigma^2} - 3e^{\mu+\frac{1}{2}\sigma^2}e^{2\mu+2\sigma^2} + 2e^{3\mu+\frac{3}{2}\sigma^2} = e^{3\mu+\frac{9}{2}\sigma^2} - 3e^{3\mu+\frac{5}{2}\sigma^2} + 2e^{3\mu+\frac{3}{2}\sigma^2} \text{ e}$$

$m_3 = e^{3\mu+\frac{3}{2}\sigma^2} [e^{3\sigma^2} - 3e^{\sigma^2} + 2]$. Fatorando o termo entre colchetes ainda chegamos a

$m_3 = e^{3\mu+\frac{3}{2}\sigma^2} [e^{\sigma^2} - 1]^2 [e^{\sigma^2} + 2]$. A Skewness será dada por:

$$\alpha_3 = \frac{m_3}{(\sqrt{V(y)})^3} = \frac{e^{3\mu+\frac{3}{2}\sigma^2} [e^{\sigma^2} - 1]^2}{e^{3\mu+\frac{3}{2}\sigma^2} [e^{\sigma^2} - 1]^{\frac{3}{2}}} [e^{\sigma^2} + 2] = \sqrt{(e^{\sigma^2} - 1)} [e^{\sigma^2} + 2].$$

Para o momento de ordem 4 $m_4 = M_4 - 4M_1M_3 + 6M_1^2M_2 - 3M_1^4$ teremos:

$$m_4 = e^{4\mu+8\sigma^2} - 4e^{\mu+\frac{\sigma^2}{2}}e^{3\mu+\frac{9}{2}\sigma^2} + 6e^{2\mu+\sigma^2}e^{2\mu+2\sigma^2} - 3e^{4\mu+2\sigma^2} = e^{4\mu+8\sigma^2} - 4e^{4\mu+5\sigma^2} + 6e^{4\mu+3\sigma^2} - 3e^{4\mu+2\sigma^2}$$

Que pode ser simplificado para $m_4 = e^{4\mu+2\sigma^2} [e^{6\sigma^2} - 4e^{3\sigma^2} + 6e^{\sigma^2} - 3]$ e fatorando o termo:

$$[e^{6\sigma^2} - 4e^{3\sigma^2} + 6e^{\sigma^2} - 3] = [e^{\sigma^2} - 1] [e^{5\sigma^2} + e^{4\sigma^2} + e^{3\sigma^2} - 3e^{2\sigma^2} - 3e^{\sigma^2} + 3] = [e^{\sigma^2} - 1]^2 [e^{4\sigma^2} + 2e^{3\sigma^2} + 3e^{2\sigma^2} - 3]$$

obtemos, finalmente: $m_4 = e^{4\mu+2\sigma^2} [e^{\sigma^2} - 1]^2 [e^{4\sigma^2} + 2e^{3\sigma^2} + 3e^{2\sigma^2} - 3]$.

Agora
$$\alpha_4 = \frac{m_4}{(\sqrt{V(y)})^4} = \frac{e^{4\mu+2\sigma^2} [e^{\sigma^2} - 1]^2}{e^{4\mu+2\sigma^2} [e^{\sigma^2} - 1]^2} [e^{4\sigma^2} + 2e^{3\sigma^2} + 3e^{2\sigma^2} - 3] = [e^{4\sigma^2} + 2e^{3\sigma^2} + 3e^{2\sigma^2} - 3]$$

que leva à curtose $k = [e^{4\sigma^2} + 2e^{3\sigma^2} + 3e^{2\sigma^2} - 3]$. Como $1 + 2 + 3 = 6$ percebe-se que $k \geq 0$ sempre, com a igualdade valendo apenas se $\sigma^2 = 0$.

Distribuição Gama:

Função gama: Vamos calcular a seguinte integral: $I(z) = \int_0^{\infty} t^z e^{-t} dt$. Fazendo por partes

$\int_a^b u dv = uv \Big|_a^b - \int_a^b v du$ com $u = t^z$; $du = z t^{z-1} dt$, $dv = e^{-t} dt$ e $v = -e^{-t}$, temos que:

$$I(z) = \int_0^{\infty} t^z e^{-t} dt = -t^z e^{-t} \Big|_0^{\infty} + z \int_0^{\infty} t^{z-1} e^{-t} dt.$$

Mas $-t^z e^{-t} \Big|_0^{\infty} = 0$, pelo t^z em $t=0$ e pelo e^{-t} em $t=\infty$, então $I(z) = z \int_0^{\infty} t^{z-1} e^{-t} dt$, o que nos leva à

relação de recorrência $I(z) = z I(z-1)$. Aplicando essa relação várias vezes temos que

$I(z) = z I(z-1) = z(z-1) I(z-2) = \dots = z(z-1)(z-2) \dots 1 \times I(0)$ $z \in \mathbb{N}$. Pela definição de

$I(z)$ temos que $I(0) = \int_0^{\infty} e^{-t} dt = -e^{-t} \Big|_0^{\infty} = 1$, portanto $I(z) = z!$.

A identidade acima foi mostrada apenas para Z inteiro positivo, mas dado que a integral existe ela pode ser utilizada para generalizar a função fatorial para reais e até mesmo complexos, com a única condição

de que a integral convirja. Assim: $z! = \int_0^{\infty} t^z e^{-t} dt$. Essa integral não apresenta problemas para $t \rightarrow \infty$ por

conta do e^{-t} mas pode ter problemas para $t \rightarrow 0$ se $z < 0$. A integral converge se $\int_0^x t^z dt$ existe. Para

$z \neq -1$ a integral $\int_0^x t^z dt = \frac{t^{z+1}}{z+1} \Big|_{t=0}$ existe se $z+1 > 0$, ou seja, $z > -1$.

A função gama é definida por: $\Gamma(z) = \int_0^{\infty} t^{z-1} e^{-t} dt$, com $\text{Re } Z > 0$. A relação com a função fatorial é

dada por $\Gamma(z) = (z-1)!$ e $z! = \Gamma(z+1)$. Formas equivalentes: vamos mudar a variável para $t = x^2$ e

$dt = 2x dx$ então $\Gamma(z) = 2 \int_0^{\infty} (x^2)^{z-1} e^{-x^2} x dx$, finalmente $\Gamma(z) = 2 \int_0^{\infty} x^{2z-1} e^{-x^2} dx$ e

$z! = 2 \int_0^{\infty} x^{2z+1} e^{-x^2} dx$. Fazendo $z = \frac{1}{2}$ vemos que $\Gamma\left(\frac{1}{2}\right) = 2 \int_0^{\infty} e^{-x^2} dx = \int_{-\infty}^{\infty} e^{-x^2} dx$ de onde extraímos

que $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$ e que $\left(-\frac{1}{2}\right)! = \sqrt{\pi}$.

A distribuição gama é dada por:

$$f_{\text{gama}}(x - x_o; \alpha, \beta) = \frac{(x - x_o)^{\alpha-1} e^{-\frac{x-x_o}{\beta}}}{\beta^{\alpha} \Gamma(\alpha)} H(x - x_o)$$

Vamos mostrar que a área sobre a curva vale sempre 1.

$$\int_{-\infty}^{+\infty} f_{\text{gama}}(x) dx = \frac{1}{\Gamma(\alpha)} \int_{x_o}^{+\infty} \left(\frac{x - x_o}{\beta}\right)^{\alpha-1} e^{-\frac{x-x_o}{\beta}} d\left(\frac{x}{\beta}\right) = \frac{1}{\Gamma(\alpha)} \int_0^{+\infty} t^{\alpha-1} e^{-t} dt = \frac{\Gamma(\alpha)}{\Gamma(\alpha)} = 1$$

Casos particulares:

$$1. \quad \alpha = 1 \text{ então } f_{\text{exponencial}}(x - x_o; \beta) = f_{\text{gama}}(x - x_o; 1, \beta) = \frac{e^{-\frac{x-x_o}{\beta}}}{\beta} H(x - x_o)$$

$$2. \quad \alpha = \nu/2 \text{ e } \beta = 2 \text{ então } f_{\chi^2}(x - x_o; \nu) = f_{\text{gama}}(x - x_o; \nu/2, 2) = \frac{(x - x_o)^{\frac{\nu}{2}-1} e^{-\frac{x-x_o}{2}}}{2^{\nu/2} \Gamma(\nu/2)} H(x - x_o)$$

é a distribuição chi-quadrado [se pronuncia qui-quadrado].

FGM da distribuição gama:

$$M(t) = \frac{1}{\Gamma(\alpha)} \int_{-\infty}^{+\infty} e^{xt} \left(\frac{x - x_o}{\beta}\right)^{\alpha-1} e^{-\frac{x-x_o}{\beta}} H(x - x_o) d\left(\frac{x}{\beta}\right) = \frac{e^{x_o t}}{\Gamma(\alpha)} \int_{-\infty}^{+\infty} e^{(x-x_o)t} \left(\frac{x - x_o}{\beta}\right)^{\alpha-1} e^{-\frac{x-x_o}{\beta}} H(x - x_o) d\left(\frac{x - x_o}{\beta}\right)$$

$$M(t) = \frac{e^{x_o t}}{\Gamma(\alpha)} \int_0^{+\infty} e^{\beta t u} u^{\alpha-1} e^{-u} du = \frac{e^{x_o t}}{\Gamma(\alpha)} \int_0^{+\infty} u^{\alpha-1} e^{-(1-\beta t)u} du = \frac{e^{x_o t}}{\Gamma(\alpha)} \frac{1}{(1-\beta t)^{\alpha}} \int_0^{+\infty} [(1-\beta t)u]^{\alpha-1} e^{-(1-\beta t)u} d[(1-\beta t)u]$$

$$M(t) = \frac{e^{x_o t}}{\Gamma(\alpha)} (1 - \beta t)^{-\alpha} \int_0^{+\infty} v^{\alpha-1} e^{-v} dv = \frac{e^{x_o t}}{\Gamma(\alpha)} (1 - \beta t)^{-\alpha} \Gamma(\alpha)$$

$$M(t) = e^{x_o t} (1 - \beta t)^{-\alpha}$$

$$\text{Logo } \varphi(t) = e^{ix_o t} (1 - i\beta t)^{-\alpha}$$

Esperança: $M'(t) = x_o e^{x_o t} (1 - \beta t)^{-\alpha} + \alpha \beta e^{x_o t} (1 - \beta t)^{-\alpha-1}$ então $\mu = M'(0) = x_o + \alpha \beta$.

Se $\mu = 0$ então $x_o = -\alpha \beta$ logo neste caso $\varphi(t) = e^{-i\alpha \beta t} (1 - i\beta t)^{-\alpha}$ e $\varphi^n(t) = e^{-in\alpha \beta t} (1 - i\beta t)^{-n\alpha}$ o que gera uma distribuição gama com $\Gamma(x - n\alpha \beta; n\alpha, \beta)$.

Cumulantes: $\ln \varphi(t) = \ln e^{ix_o t} - \alpha \ln(1 - i\beta t) = ix_o t - \alpha \sum_{k=1}^{\infty} \frac{(-i)^k (-1)^{k-1} \beta^k}{k} t^k$, pela série do logaritmo

$$\ln(1+x) = \sum_{k=1}^{\infty} \frac{(-1)^{k-1}}{k} x^k, \text{ ou seja, } \ln \varphi(t) = ix_o t + \alpha \sum_{k=1}^{\infty} \frac{i^k k! \beta^k}{k} \frac{t^k}{k!}, \text{ finalmente:}$$

$$\ln \varphi(t) = i(x_o + \alpha \beta)t + \sum_{k=2}^{\infty} \left[i^k (k-1)! \alpha \beta^k \right] \frac{t^k}{k!}$$

Comparando com $\ln \varphi(t) = \sum_{k=0}^{\infty} i^k c_k \frac{t^k}{k!}$, da definição dos cumulantes, vemos que $c_1 = \mu = x_o + \alpha \beta$ e que

$c_k = (k-1)! \alpha \beta^k$, de onde extraímos que $c_2 = \sigma^2 = \alpha \beta^2$, $c_3 = m_3 = 2\alpha \beta^3$ e $c_4 = 6\alpha \beta^4$. Assim a curtose vale

$k = \frac{6\alpha \beta^4}{\alpha^2 \beta^4} = \frac{6}{\alpha}$, positiva, logo leptocúrtica. Usando o fato de que $c_4 = m_4 - 3\sigma^4$ vemos que

$6\alpha \beta^4 = m_4 - 3\alpha^2 \beta^4$ e extraímos $m_4 = 3\alpha(\alpha + 2)\beta^4$.

Aditividade da distribuição gama:

Sejam x_1, x_2, \dots, x_n n v.a.'s independentes que seguem a distribuição gama de mesmo β mas com diferentes α 's e x_o 's, ou seja, $f(x_i) = \text{Gama}(x_i - x_{oi}; \alpha_i, \beta)$. Então a variável $z = x_1 + x_2 + \dots + x_n$ também segue a distribuição com $x_o = x_{o1} + x_{o2} + \dots + x_{on}$ e $\alpha = \alpha_1 + \alpha_2 + \dots + \alpha_n$ e mesmo β . Pelo

teorema da convolução $\varphi_z(t) = e^{ix_{o1}t} (1-i\beta t)^{-\alpha_1} e^{ix_{o2}t} (1-i\beta t)^{-\alpha_2} \dots e^{ix_{on}t} (1-i\beta t)^{-\alpha_n}$ logo

$$\varphi_z(t) = e^{i(x_{o1}+x_{o2}+\dots+x_{on})t} (1-i\beta t)^{-(\alpha_1+\alpha_2+\dots+\alpha_n)}$$

que é a função característica da distribuição gama.

Convergência para a Normal:

Se $\alpha \rightarrow \infty$ podemos usar o truque do logaritmo para analisar o comportamento assintótico da distribuição gama. Aplicando o logaritmo na função característica temos:

$\ln[\varphi(t)] = ix_o t - \alpha \ln[1-i\beta t]$, usando $\ln(1-x) = -\left[x + \frac{x^2}{2} + \frac{x^3}{3} + \frac{x^4}{4} + \dots\right]$ com $x = i\beta t$ obtemos,

até segunda ordem, $\ln(1-x) \cong -i\beta t - \frac{(i\beta t)^2}{2} = -i\beta t + \frac{\beta^2}{2} t^2$. Nesse caso temos então que

$\ln[\varphi(t)] = i(x_o + \alpha\beta)t - \frac{\alpha\beta^2}{2} t^2$ ou $\varphi(t) = e^{i(x_o + \alpha\beta)t - \frac{\alpha\beta^2}{2} t^2}$ que é a função característica de uma

normal com $\mu = x_o + \alpha\beta$ e $\sigma^2 = \alpha\beta^2$. Logo para $\lim_{\alpha \rightarrow \infty} \Gamma(x - x_o; \alpha, \beta) \rightarrow N(x - x_o; \alpha\beta, \alpha\beta^2)$.

Distribuição Chi-quadrado:

Na função Gama vamos fazer $\alpha = \frac{\nu}{2}$ e $\beta = 2$. Nesse caso temos: $\alpha = \frac{\nu}{2}$ e $\beta = 2$ então

$$f_{\chi^2}(x - x_o; \nu) = \frac{(x - x_o)^{\frac{\nu}{2}-1} e^{-\frac{x-x_o}{2}}}{2^{\nu/2} \Gamma(\nu/2)} H(x - x_o).$$

Distribuições t-student e F.

Agora suponha a variável $y = x^2$ onde x segue uma normal $N(0,1)$. Então y segue a distribuição

χ^2 com $f_y(y) = \frac{1}{\sqrt{2\pi\sigma}} y^{-1/2} e^{-\frac{y}{2\sigma^2}} H(y)$. Agora a v.a. $S^2 = x_1^2 + x_2^2 + \dots + x_n^2$ segue a

distribuição Gama com $f(S^2) = \dots$

Suponha que x segue uma normal $N(\mu, \sigma)$ cuja função característica vale $\varphi_x(t) = e^{i\mu t - \frac{\sigma^2 t^2}{2}}$.

Qual a distribuição de $z = x_1 + x_2 + \dots + x_n$ com x 's iid? A nova função característica será dada por

$$\varphi_x(t) = e^{i\mu t - \frac{\sigma^2 t^2}{2}} = e^{i\mu t - \frac{(\sqrt{n}\sigma)^2 t^2}{2}} \text{ logo } z \text{ segue uma normal } N(n\mu, \sqrt{n}\sigma).$$

Agora vamos mudar a v.a. para a média $\bar{x} = \frac{z}{n} = \frac{1}{n} \sum_j x_j$. Nesse caso $f_{\bar{x}}\left(\frac{z}{n}\right) = n f_z(n\bar{x})$, ou seja,

$$f_{\bar{x}}(\bar{x}) = \frac{n}{2\pi} \int_{-\infty}^{+\infty} e^{-in\bar{x}t} e^{i\mu t - \frac{\sigma^2 t^2}{2}} dt = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-in\bar{x}t} e^{i\mu t - \frac{\left(\frac{\sigma}{\sqrt{n}}\right)^2 (nt)^2}{2}} d(nt)$$

Chamando $s = nt$ temos que

$$f_{\bar{x}}(\bar{x}) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-i\bar{x}s} e^{i\mu s - \frac{\left(\frac{\sigma}{\sqrt{n}}\right)^2 s^2}{2}} ds = N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Distribuição Beta:

Podemos iniciar a distribuição Beta descobrindo quanto vale $n!m!$. Usando a forma

$$z! = 2 \int_0^{\infty} x^{2z+1} e^{-x^2} dx \text{ podemos reescrever esse produto como:}$$

$$n!m! = 4 \int_0^{\infty} x^{2n+1} e^{-x^2} dx \int_0^{\infty} y^{2m+1} e^{-y^2} dy = 4 \int_0^{\infty} \int_0^{\infty} e^{-(x^2+y^2)} x^{2n+1} y^{2m+1} dx dy.$$

Vamos trocar para coordenadas polares $x = r \cos \theta$, $y = r \sin \theta$, $x^2 + y^2 = r^2$ e $dx dy = r dr d\theta$.

Temos que integrar apenas no primeiro quadrante, pois $x > 0$ e $y > 0$, logo $0 \leq \theta \leq \frac{\pi}{2}$ e $0 \leq r < \infty$,

logo:

$$n!m! = 4 \int_0^\infty \int_0^{\pi/2} e^{-r^2} r^{2n+1} r^{2m+1} \cos^{2n+1} \theta \sin^{2m+1} \theta r dr d\theta = \left[2 \int_0^\infty r^{2(n+m+1)+1} e^{-r^2} dr \right] \left[2 \int_0^{\pi/2} \cos^{2n+1} \theta \sin^{2m+1} \theta d\theta \right]$$

$$\text{Ou seja: } n!m! = (n+m+1)! 2 \int_0^{\pi/2} \cos^{2n+1} \theta \sin^{2m+1} \theta d\theta$$

Fazendo $t = \cos^2 \theta$, $1-t = 1 - \cos^2 \theta = \sin^2 \theta$ e $dt = -2 \sin \theta \cos \theta d\theta$ transformamos a integral acima em

$$n!m! = (n+m+1)! \int_0^{\pi/2} [\cos^2 \theta]^n [\sin^2 \theta]^m (2 \sin \theta \cos \theta d\theta) = (n+m+1)! \int_1^0 t^n (1-t)^m (-dt) = (n+m+1)! \int_0^1 t^n (1-t)^m dt$$

$$\text{Então sabemos que: } \int_0^1 t^n (1-t)^m dt = \frac{n!m!}{(n+m+1)!}.$$

$$\text{A função Beta é definida como } B(n, m) = \int_0^1 t^{n-1} (1-t)^{m-1} dt = \frac{(n-1)!(m-1)!}{(n+m-1)!} = \frac{\Gamma(n)\Gamma(m)}{\Gamma(n+m)}.$$

A distribuição Beta, definida no intervalo $0 \leq x \leq 1$ apenas, é dada por:

$$f_{beta}(x; \alpha, \beta) = \frac{x^{\alpha-1} (1-x)^{\beta-1}}{B(\alpha, \beta)} H(x) H(1-x)$$

FGM da Beta:

$$M_{beta}(t) = \frac{1}{B(\alpha, \beta)} \int_0^1 e^{xt} x^{\alpha-1} (1-x)^{\beta-1} dx = \frac{1}{B(\alpha, \beta)} \sum_{k=0}^{\infty} \frac{t^k}{k!} \int_0^1 x^k x^{\alpha-1} (1-x)^{\beta-1} dx$$

$$M_{beta}(t) = \frac{1}{B(\alpha, \beta)} \sum_{k=0}^{\infty} \frac{t^k}{k!} \int_0^1 x^{\alpha+k-1} (1-x)^{\beta-1} dx = \sum_{k=0}^{\infty} \frac{B(\alpha+k, \beta)}{B(\alpha, \beta)} \frac{t^k}{k!}$$

$$M_{beta}(t) = \sum_{k=0}^{\infty} \frac{B(\alpha+k, \beta)}{B(\alpha, \beta)} \frac{t^k}{k!}$$

Daqui extraímos que: $M_k = \frac{B(\alpha+k, \beta)}{B(\alpha, \beta)}$. Em termos dos fatoriais temos:

$$M_k = \frac{(\alpha+k-1)!(\beta-1)!}{(\alpha+k+\beta-1)!} \frac{(\alpha+\beta-1)!}{(\alpha-1)!(\beta-1)!}, \text{ ou seja, } M_k = \frac{(\alpha+k-1)!}{(\alpha+k-1+\beta)!} \frac{(\alpha+\beta-1)!}{(\alpha-1)!}.$$

$$1. \quad M_0 = \frac{(\alpha-1)!}{(\alpha-1+\beta)!} \frac{(\alpha+\beta-1)!}{(\alpha-1)!} = 1.$$

$$2. \quad M_1 = \frac{(\alpha)!}{(\alpha+\beta)!} \frac{(\alpha+\beta-1)!}{(\alpha-1)!} = \frac{\alpha}{\alpha+\beta} \quad \text{então } \mu = \frac{\alpha}{\alpha+\beta}.$$

$$3. \quad M_2 = \frac{(\alpha+1)!}{(\alpha+\beta+1)!} \frac{(\alpha+\beta-1)!}{(\alpha-1)!} = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} \quad \text{então } \sigma^2 = M_2 - \mu^2 \text{ será dado por}$$

$$\sigma^2 = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} - \frac{\alpha^2}{(\alpha+\beta)^2} = \frac{\alpha}{(\alpha+\beta)} \left[\frac{(\alpha+1)}{(\alpha+\beta+1)} - \frac{\alpha}{(\alpha+\beta)} \right] \quad \text{finalmente}$$

$$\sigma^2 = \frac{\alpha\beta}{(\alpha+\beta+1)(\alpha+\beta)^2}.$$

$$4. \quad M_3 = \frac{(\alpha+2)!}{(\alpha+\beta+2)!} \frac{(\alpha+\beta-1)!}{(\alpha-1)!} = \frac{\alpha(\alpha+1)(\alpha+2)}{(\alpha+\beta)(\alpha+\beta+1)(\alpha+\beta+2)}.$$

$$5. \quad M_4 = \frac{(\alpha+3)!}{(\alpha+\beta+3)!} \frac{(\alpha+\beta-1)!}{(\alpha-1)!} = \frac{\alpha(\alpha+1)(\alpha+2)(\alpha+3)}{(\alpha+\beta)(\alpha+\beta+1)(\alpha+\beta+2)(\alpha+\beta+3)}.$$

Distribuição Logística:

$$F(x; \theta) = \frac{1}{1 + e^{-\frac{x-x_0}{\theta}}} \quad \text{então } f(x; \theta) = \frac{d}{dx} \left(1 + e^{-\frac{x-x_0}{\theta}} \right)^{-1} = \frac{1}{\theta} \frac{e^{-\frac{x-x_0}{\theta}}}{\left(1 + e^{-\frac{x-x_0}{\theta}} \right)^2}$$

$$M(t) = \int_{-\infty}^{+\infty} e^{tx} \frac{dF(x)}{dx} dx = e^{tx} F(x) \Big|_{-\infty}^{+\infty} - t \int_{-\infty}^{+\infty} e^{tx} F(x) dx$$

$$M(t) = e^{x_o t} \int_{-\infty}^{+\infty} e^{\theta t \left(\frac{x-x_o}{\theta} \right)} \frac{e^{-\frac{x-x_o}{\theta}}}{\left(1 + e^{-\frac{x-x_o}{\theta}} \right)^2} d \frac{x-x_o}{\theta} = e^{x_o t} \int_{-\infty}^{+\infty} \frac{(e^z)^{\theta t - 1}}{(1 + e^{-z})^2} dz$$

$$z = \ln s \quad dz = \frac{1}{s} ds$$

$$M(t) = e^{x_o t} \int_0^{+\infty} \frac{(e^{\ln s})^{\theta t - 1}}{(1 + e^{-\ln s})^2} \frac{1}{s} ds = e^{x_o t} \int_0^{+\infty} \frac{s^{\theta t}}{(s+1)^2} ds$$

$$s = \frac{t}{(1-t)} ; \quad ds = \frac{1}{(1-t)^2} dt, \quad s+1 = \frac{t}{(1-t)} + 1 = \frac{1}{(1-t)}$$

$$M(t) = e^{x_o t} \int_0^1 \frac{\frac{t^{\theta t}}{(1-t)^{\theta t}}}{\frac{1}{(1-t)^2}} \frac{1}{(1-t)^2} dt = e^{x_o t} \int_0^1 t^{\theta t + 1 - 1} (1-t)^{-\theta t + 1 - 1} dt = e^{x_o t} B(1 + \theta t, 1 - \theta t)$$

Distribuição t de Student.

Uma variável aleatória t de Student é dada por uma variável normal cuja variância é igual à recíproca de uma variável que segue uma distribuição gama. Se a variável x segue uma normal com média nula mas variância $\frac{1}{\sigma^2} = \psi$ desconhecida então $f(x|\psi) = \sqrt{\frac{\psi}{2\pi}} e^{-\frac{\psi}{2}x^2}$. A ψ segue uma distribuição

gama com parâmetros $f_{gama}(\psi; \alpha, \beta) = \frac{1}{\beta^\alpha \Gamma(\alpha)} \psi^{\alpha-1} e^{-\frac{\psi}{\beta}} H(\psi)$, então x segue a distribuição:

$$f(x) = \sqrt{\frac{1}{2\pi}} \frac{1}{\beta^\alpha \Gamma(\alpha)} \int_0^\infty d\psi \psi^{\alpha - \frac{1}{2}} e^{-\frac{\psi}{\beta}} e^{-\frac{\psi}{2}x^2} = \sqrt{\frac{1}{2\pi}} \frac{1}{\beta^\alpha \Gamma(\alpha)} \int_0^\infty d\psi \psi^{\alpha - \frac{1}{2}} e^{-\left[1 + \frac{\beta x^2}{2}\right] \frac{\psi}{\beta}}$$

Ou seja, $f(x) = \sqrt{\frac{1}{2\pi}} \frac{\beta^{\alpha+\frac{1}{2}}}{\beta^\alpha \Gamma(\alpha)} \left[1 + \frac{\beta x^2}{2}\right]^{-\alpha-\frac{1}{2}} \int_0^\infty \left[1 + \frac{\beta x^2}{2}\right] \frac{d\psi}{\beta} \left[1 + \frac{\beta x^2}{2}\right]^{\alpha-\frac{1}{2}} \frac{\psi^{\alpha-\frac{1}{2}}}{\beta^{\alpha-\frac{1}{2}}} e^{-\left[1 + \frac{\beta x^2}{2}\right] \frac{\psi}{\beta}},$ de

modo que $f(x) = \sqrt{\frac{\beta}{2\pi}} \frac{1}{\Gamma(\alpha)} \left[1 + \frac{\beta x^2}{2}\right]^{-\alpha-\frac{1}{2}} \int_0^\infty z^{\alpha+\frac{1}{2}-1} e^{-z} dz = \sqrt{\frac{\beta}{2\pi}} \frac{\Gamma\left(\alpha + \frac{1}{2}\right)}{\Gamma(\alpha)} \left[1 + \frac{\beta x^2}{2}\right]^{-\alpha-\frac{1}{2}}.$ Para

$\alpha = \nu/2$ e $\beta = \frac{2}{\nu}$ chegamos a distribuição t de Student dada por $f(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi} \Gamma\left(\frac{\nu}{2}\right)} \left[1 + \frac{x^2}{\nu}\right]^{-\frac{\nu+1}{2}}.$

A distribuição t de Student não possui função geradora dos momentos mas possui função característica

dada por $\varphi(t) = \frac{K_{\nu/2}(\nu|t|)(\sqrt{\nu}|t|)^{\nu/2}}{\Gamma\left(\frac{\nu}{2}\right) 2^{\frac{\nu}{2}-1}}$ onde $K_{\nu/2}(x)$ é a função de Bessel modificada. Note entretanto

que é uma função do módulo de t , não diferenciável, e portanto não pode ser utilizada para cálculo dos momentos.

Distribuição normal multivariada:

Se as v.a.s correlacionadas seguem uma distribuição normal multivariada queremos mostrar que a função densidade de probabilidade conjunta é dada por:

$f(\vec{x}) = A e^{-\frac{1}{2} \sum_i \sum_j (x_i - \mu_i) V_{ij}^{-1} (x_j - \mu_j)}$ onde V é a matriz de variância-covariância. O fato de que se trata de uma matriz definida positiva garante que o expoente será sempre negativo e f caia a zero para grandes valores de x . Antes de mais nada precisamos encontrar a constante normalizadora A tal que

$\iiint A e^{-\frac{1}{2} \sum_i \sum_j (x_i - \mu_i) V_{ij}^{-1} (x_j - \mu_j)} dx_1 dx_2 \cdots dx_n = 1.$ Para realizar essa operação precisamos antes diagonalizar a

matriz V^{-1} . Voltando à distribuição normal multivariada temos que a integral

$\iiint A e^{-\frac{1}{2} \sum_i \sum_j (x_i - \mu_i) V_{ij}^{-1} (x_j - \mu_j)} dx_1 dx_2 \cdots dx_n = 1$ é complicada por causa dos termos cruzados envolvendo x_i

e x_j . Então a idéia é diagonalizar e ficar apenas com termos contendo z_i^2 . Para tanto vamos começar

definindo $q_i = x_i - \mu_i$ e reescrever a integral como $A \iiint e^{-\frac{1}{2} \sum_i \sum_j q_i V_{ij}^{-1} q_j} dq_1 dq_2 \cdots dq_n = 1.$ Agora notamos

que temos $A \iiint e^{-\frac{1}{2} \vec{q}' V^{-1} \vec{q}} dq_1 dq_2 \cdots dq_n = 1$ e diagonalizamos a matriz V^{-1} no expoente com o seguinte

truque: $A \iiint e^{-\frac{1}{2} \vec{q}' S (S' V^{-1} S) S' \vec{q}} dq_1 dq_2 \cdots dq_n = A \iiint e^{-\frac{1}{2} (S' \vec{q})' (S' V^{-1} S) (S' \vec{q})} dq_1 dq_2 \cdots dq_n = 1$. Agora mudamos

para as variáveis giradas, $\vec{z} = S' \vec{q}$, ou seja, $z_i = \sum_j S'_{ij} q_j$. Multiplicando pela inversa de S' temos que

$\vec{q} = S \vec{z}$, ou seja, $q_i = \sum_j S_{ij} z_j$ de onde tiramos que $\frac{\partial q_i}{\partial z_j} = S_{ij}$ e que a matriz Jacobiana J é a própria

matriz S . Sabemos que $dq_1 dq_2 \cdots dq_n = \det(J) dz_1 dz_2 \cdots dz_n$. Mas, nesse caso, como $J = S$ e $\det(S) = 1$ então $dq_1 dq_2 \cdots dq_n = dz_1 dz_2 \cdots dz_n$ e a integral fica na forma

$A \iiint e^{-\sum_i \frac{z_i^2}{2\lambda_i}} dz_1 dz_2 \cdots dz_n = A \prod_i \int_{-\infty}^{+\infty} e^{-\frac{z_i^2}{2\lambda_i}} dz_i = A \prod_i \sqrt{2\lambda_i} \int_{-\infty}^{+\infty} e^{-u^2} du = A \prod_i \sqrt{2\pi\lambda_i} = 1$. Isso significa que

$A = \frac{1}{(\sqrt{2\pi})^n \sqrt{\lambda_1 \lambda_2 \cdots \lambda_n}}$ onde λ_i são os autovalores de V . Agora, usamos o fato de que a

diagonalização de uma matriz preserva o determinante e que, portanto, $\det(V) = \lambda_1 \lambda_2 \cdots \lambda_n$. Daí

obtemos que $A = \frac{1}{(\sqrt{2\pi})^n \sqrt{\det V}}$.

A distribuição Normal multivariada é dada por:

$$f(\vec{x}) = \frac{e^{-\frac{1}{2} \sum_i \sum_j (x_i - \mu_i) V_{ij}^{-1} (x_j - \mu_j)}}{(\sqrt{2\pi})^n \sqrt{\det V}} = \frac{e^{-\frac{1}{2} (\vec{x} - \vec{\mu})' V^{-1} (\vec{x} - \vec{\mu})}}{(\sqrt{2\pi})^n \sqrt{\det V}}$$

Para achar a matriz de variância-covariância entre as variáveis x notamos que as variáveis z 's são independentes, pois $f(z_i, z_j) = f_i(z_i) f_j(z_j)$, seguindo uma normal com esperança nula e variância

λ_i , ou seja, $E[z_i] = 0$ e $E[z_i z_j] = \lambda_i \delta_{ij}$. A relação entre as variáveis z 's e as x 's originais é:

$x_i = \mu_i + \sum_j S_{ij} z_j$, de onde tiramos que $E[x_i] = \mu_i + \sum_j S_{ij} E[z_j] = \mu_i$ e $x_i - \mu_i = \sum_j S_{ij} z_j$, logo,

$(x_i - \mu_i)(x_k - \mu_k) = \sum_j \sum_l S_{ij} S_{kl} z_j z_l$ então:

$$E[(x_i - \mu_i)(x_k - \mu_k)] = \sum_j \sum_l S_{kl} S_{ij} E[z_j z_l] = \sum_j \sum_l \frac{1}{\lambda_j} S_{kl} S_{ij} \delta_{jl} = \sum_j \lambda_j S_{ij} S'_{jk} = SDS' = V.$$

Geração de variáveis correlacionadas – método da decomposição de Cholesky.

Sabemos que a matriz de variância-covariância V é simétrica e definida positiva. Toda matriz dessa forma pode ser decomposta em uma multiplicação de matrizes triangulares superior e inferior, ou seja,

queremos escrever $V = \Delta \Delta'$ onde $\Delta = \begin{pmatrix} \delta_{11} & 0 & 0 \\ \delta_{21} & \delta_{22} & 0 \\ \delta_{31} & \delta_{32} & \delta_{33} \end{pmatrix}$ é uma matriz triangular inferior e

$\Delta' = \begin{pmatrix} \delta_{11} & \delta_{21} & \delta_{31} \\ 0 & \delta_{22} & \delta_{32} \\ 0 & 0 & \delta_{33} \end{pmatrix}$ é triangular superior. Sabemos que qualquer matriz dada por $M = AA'$ é

simétrica pois $M' = (AA')' = A''A' = AA' = M$. Logo $\Delta \Delta'$ é uma matriz simétrica. Agora note que

$$\Delta \Delta' = \begin{pmatrix} \delta_{11} & 0 & 0 \\ \delta_{21} & \delta_{22} & 0 \\ \delta_{31} & \delta_{32} & \delta_{33} \end{pmatrix} \begin{pmatrix} \delta_{11} & \delta_{21} & \delta_{31} \\ 0 & \delta_{22} & \delta_{32} \\ 0 & 0 & \delta_{33} \end{pmatrix} = \begin{pmatrix} \delta_{11}^2 & \delta_{11}\delta_{21} & \delta_{11}\delta_{31} \\ \delta_{11}\delta_{21} & \delta_{21}^2 + \delta_{22}^2 & \delta_{11}\delta_{31} \\ \delta_{11}\delta_{31} & \delta_{11}\delta_{31} & \delta_{31}^2 + \delta_{32}^2 + \delta_{33}^2 \end{pmatrix}.$$

Percebe-se do processo que $\delta_{11}^2 = V_{11} \rightarrow \delta_{11} = \sqrt{V_{11}}$ e $\delta_{11}\delta_{21} = V_{12} \rightarrow \delta_{21} = \frac{V_{12}}{\sqrt{V_{11}}}$ e

$$\delta_{11}\delta_{31} = V_{13} \rightarrow \delta_{31} = \frac{V_{13}}{\sqrt{V_{11}}} \quad \delta_{21}^2 + \delta_{22}^2 = V_{22} \rightarrow \delta_{22}^2 = V_{22} - \frac{V_{12}^2}{V_{11}} = \frac{V_{11}V_{22} - V_{12}^2}{V_{11}} \rightarrow \delta_{22} = \sqrt{\frac{V_{11}V_{22} - V_{12}^2}{V_{11}}}.$$
 O

processo pode ser continuado, mas existem pacotes capazes de realizar a decomposição de Cholesky. Note que é necessário que V seja definida positiva para que as raízes sejam reais.

Agora geramos n v.a.s independentes com esperança nula e variância unitária, i.e., $E[x_i] = 0$;

$E[x_i x_j] = \delta_{ij}$ e com essas variáveis construímos as variáveis z 's dadas por $z_i = \sum_j \Delta_{ij} x_j + \bar{z}_i$ portanto

$E[z_i] = \sum_j \Delta_{ij} E[x_j] + E[\bar{z}_i] = \bar{z}_i$. Nesse caso $(z_i - E[z_i]) = (z_i - \bar{z}_i) = \sum_j \Delta_{ij} x_j$. Daí extraímos que

$(z_k - \bar{z}_k) = \sum_l \Delta_{kl} x_l$ e $(z_i - \bar{z}_i)(z_k - \bar{z}_k) = \sum_l \sum_j \Delta_{kl} \Delta_{ij} x_j x_l$. Aplicando a esperança de ambos os

lados:

$$E[(z_i - \bar{z}_i)(z_k - \bar{z}_k)] = \sum_l \sum_j \Delta_{kl} \Delta_{ij} E[x_j x_l] = \sum_l \sum_j \Delta_{kl} \Delta_{ij} \delta_{jl} = \sum_j \Delta_{ij} \Delta_{kj} = \sum_j \Delta_{ij} \Delta'_{jk} = \Delta \Delta' = V$$

Conseguimos então um conjunto de n v.a.s z_i com esperança e variância determinadas.

Aspectos fundamentais dessa técnica são: (1) A matriz de partida tem que ser simétrica e definida positiva; (2) as variáveis independentes devem ter esperança nula e (3) variância igual a 1.