

Análise Multivariada.

Vamos agora criar uma função vetorial de conjunto $\vec{x}_v(A): \Omega \rightarrow \mathbb{R}^n$ que possui as componentes x_1, x_2, \dots, x_n em que cada x_j é uma v.a. Neste caso $\{x_{vi} \leq x_i\}$ e $\{x_{vj} \leq x_j\}$ são dois eventos, assim como $\{x_{vi} \leq x_i\} + \{x_{vj} \leq x_j\} = \{x_{vi} \leq x_i, x_{vj} \leq x_j\}$. Para facilitar a compreensão e as demonstrações vamos trabalhar apenas com o caso bivariado, ou seja, duas v.a.s, e depois generalizar para n . Facilita, nesse estágio, chamar uma v.a. de x e a outra de y .

Distribuição conjunta [Joint Distribution]

$$F(x, y) = P\{x_v \leq x, y_v \leq y\}$$

Propriedades:

$$1. \quad F(-\infty, y) = F(x, -\infty) = 0 \text{ e } F(+\infty, +\infty) = 1.$$

Prova: $\{x_v \leq -\infty, y_v \leq y\} \subset \{x_v = -\infty\} \rightarrow P\{x_v \leq -\infty, y_v \leq y\} \leq P\{x_v = -\infty\} = 0$, então $0 \geq P\{x_v \leq -\infty, y_v \leq y\} \geq 0$ logo $F(-\infty, y) = 0$. Troca o nome das v.a.s e o teorema continua válido.

Para a segunda parte basta notar que $\{x_v \leq +\infty, y_v \leq +\infty\} = \Omega$ logo $P\{x_v \leq +\infty, y_v \leq +\infty\} = P\{\Omega\} = 1$.

$$2. \quad P\{x_1 < x_v \leq x_2, y_v \leq y\} = F(x_2, y) - F(x_1, y)$$

Para mostrar isso basta usar a seguinte partição:

$$\{x_v \leq x_2, y_v \leq y\} \equiv \{x_v \leq x_1, y_v \leq y\} + \{x_1 < x_v \leq x_2, y_v \leq y\}, \quad \text{logo}$$

$$P\{x_v \leq x_2, y_v \leq y\} = P\{x_v \leq x_1, y_v \leq y\} + P\{x_1 < x_v \leq x_2, y_v \leq y\}, \text{ ou seja:}$$

$$F(x_2, y) = F(x_1, y) + P\{x_1 < x_v \leq x_2, y_v \leq y\}$$

De modo análogo é claro que $P\{x_v \leq x, y_1 < y_v \leq y_2\} = F(x, y_2) - F(x, y_1)$

$$3. \quad P\{x_1 < x_v \leq x_2, y_1 < y_v \leq y_2\} = F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1)$$

Vamos tomar a partição:

$$\{x_1 < x_v \leq x_2, y_v \leq y_2\} \equiv \{x_1 < x_v \leq x_2, y_v \leq y_1\} + \{x_1 < x_v \leq x_2, y_1 < y_v \leq y_2\}$$

Então:

$$P\{x_1 < x_v \leq x_2, y_v \leq y_2\} = P\{x_1 < x_v \leq x_2, y_v \leq y_1\} + P\{x_1 < x_v \leq x_2, y_1 < y_v \leq y_2\}$$

$$F(x_2, y_2) - F(x_1, y_2) = F(x_2, y_1) - F(x_1, y_1) + P\{x_1 < x_v \leq x_2, y_1 < y_v \leq y_2\}$$

$$4. \quad P\{x < x_v \leq x + \delta x, y < y_v \leq y + \delta y\} = \frac{\partial^2 F}{\partial x \partial y} \delta x \delta y$$

Fazendo $x_1 = x$, $x_2 = x + \delta x$, $y_1 = y$ e $y_2 = y + \delta y$ em (3) e usando o fato de que:

$$F(x + \delta x, y + \delta y) - F(x, y + \delta y) = \frac{F(x + \delta x, y + \delta y) - F(x, y + \delta y)}{\delta x} \delta x = \frac{\partial F(x, y + \delta y)}{\partial x} \delta x$$

$$F(x + \delta x, y) - F(x, y) = \frac{F(x + \delta x, y) - F(x, y)}{\delta x} \delta x = \frac{\partial F(x, y)}{\partial x} \delta x$$

Então

$$[F(x + \delta x, y + \delta y) - F(x, y + \delta y)] - [F(x + \delta x, y) - F(x, y)] = \frac{\partial F(x, y + \delta y)}{\partial x} \delta x - \frac{\partial F(x, y)}{\partial x} \delta x$$

$$P\{x < x_v \leq x + \delta x, y < y_v \leq y + \delta y\} = \left[\frac{\frac{\partial F(x, y + \delta y)}{\partial x} - \frac{\partial F(x, y)}{\partial x}}{\delta y} \right] \delta y \delta x = \frac{\partial^2 F(x, y)}{\partial x \partial y} \delta x \delta y$$

Note que $\frac{\partial^2 F(x, y)}{\partial x \partial y} \geq 0$ sempre.

Densidade de probabilidade conjunta [joint density probability]

Definimos a fdp conjunta agora como: $f(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}$.

O reverso é dado por: $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$

Prova do reverso: $\frac{\partial}{\partial y} \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv = \int_{-\infty}^x du \frac{\partial}{\partial y} \int_{-\infty}^y f(u, v) dv = \int_{-\infty}^x f(u, y) du$ e

$$\frac{\partial}{\partial x} \frac{\partial}{\partial y} \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv = \frac{\partial}{\partial x} \int_{-\infty}^x f(u, y) du = f(x, y) \text{ logo:}$$

$$f(x, y) = \frac{\partial^2}{\partial x \partial y} \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$$

Se queremos a probabilidade de encontrar $(x, y) \in A$ então devemos fazer a seguinte integral múltipla:

$$P\{(x, y) \in A\} = \iint_{(x, y) \in A} f(x, y) dx dy$$

Também exigimos aqui que:

$$F(\infty, \infty) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$$

Para ser uma densidade de probabilidade multivariada, então, $f(x, y) \geq 0$ e $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$.

Distribuição e Densidades Marginais:

Suponha que queremos a estatística de apenas uma das variáveis sem interessar o valor da outra. Notamos que $\{x_v \leq x\} \equiv \{x_v \leq x, y_v \leq \infty\}$ assim como $\{y_v \leq y\} \equiv \{x_v \leq \infty, y_v \leq y\}$. Então

$F_x(x) = F(x, \infty)$ e $F_y(y) = F(\infty, y)$ são as distribuições marginais de x e de y . Note então que:

$$F_x(x) = \int_{-\infty}^x \int_{-\infty}^{+\infty} f(u, y) du dy = \int_{-\infty}^x \left[\int_{-\infty}^{+\infty} f(u, y) dy \right] du$$

e

$$F_y(y) = \int_{-\infty}^y \int_{-\infty}^{+\infty} f(x, v) dx dv = \int_{-\infty}^y \left[\int_{-\infty}^{+\infty} f(x, v) dx \right] dv$$

Ou seja integra-se em todas as possibilidades das outras variáveis para se obter a distribuição de uma variável independente dos valores das outras.

Nesse caso as densidades marginais serão dadas por:

$$f_x(x) = \frac{d}{dx} F_x(x) = \frac{d}{dx} \int_{-\infty}^x \left[\int_{-\infty}^{+\infty} f(u, y) dy \right] du = \int_{-\infty}^{+\infty} f(x, y) dy$$

e

$$f_y(y) = \frac{d}{dy} F_y(y) = \frac{d}{dy} \int_{-\infty}^y \left[\int_{-\infty}^{+\infty} f(x, v) dx \right] dv = \int_{-\infty}^{+\infty} f(x, y) dx$$

Fica claro então que:

$$\int_{-\infty}^{+\infty} f_x(x) dx = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1 \text{ e } \int_{-\infty}^{+\infty} f_y(y) dy = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1.$$

Caso discreto:

De forma análoga à distribuições univariadas os casos de distribuições discretas pode ser implementado com a função delta de Dirac generalizada para mais de uma dimensão definida como:

$$\delta(\vec{x} - \vec{x}_o) = \delta(x_1 - x_{1o}) \delta(x_2 - x_{2o}) \cdots \delta(x_n - x_{no}).$$

Funções escalares $f(\vec{x}): \mathbb{R}^n \rightarrow \mathbb{R}$ **multivariadas.**

Vamos criar a v.a. z_v à partir das v.a.s x e y através da função escalar $z_v = g(x, y)$ que associa um vetor em \mathbb{R}^2 a um número real em \mathbb{R} . Nesse caso o evento $\{z_v \leq z\} \equiv \{g(x, y) \leq z\}$ e a distribuição de probabilidade de z será dada por:

$$F_z(z) = \iint_{g(x,y) \leq z} f(x, y) dx dy$$

enquanto a fdp da v.a. z dada por:

$$f_z(z) = \iint_{z < g(x,y) \leq z+dz} f(x, y) dx dy$$

A integral pode complicar devido à restrição $g(x, y) \leq z$ ou $z < g(x, y) \leq z + dz$. Em vários casos pode ser vantajoso trocar as variáveis de integração para $u(x, y)$ e $w(x, y)$ através da regra do Jacobiano:

$$\iint_V f(x, y) dx dy = \iint_V f(u, w) J(u, w) du dw$$

Onde o Jacobiano é dado pela matriz: $J = \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial y}{\partial u} \\ \frac{\partial x}{\partial w} & \frac{\partial y}{\partial w} \end{pmatrix}$. O apêndice xxx traz a demonstração dessa

regra. Podemos aplicá-la ao caso da transformação de coordenadas retangulares para polares, em que $x = r \cos \theta$ e $y = r \sin \theta$. Portanto:

$$J = \det \begin{pmatrix} \frac{\partial x}{\partial r} & \frac{\partial y}{\partial r} \\ \frac{\partial x}{\partial \theta} & \frac{\partial y}{\partial \theta} \end{pmatrix} = \det \begin{pmatrix} \cos \theta & \sin \theta \\ -r \sin \theta & r \cos \theta \end{pmatrix} = r \cos^2 \theta + r \sin^2 \theta = r.$$

Isso significa que $dx dy = r dr d\theta$.

Operação esperança multivariada:

Agora a operação esperança de qualquer função escalar das v.a.s x e y $z = g(x, y)$ é dada por:

$$E[g(x, y)] = \int_{-\infty}^{\infty} z f_z(z) dz = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy$$

Dessa definição podemos extrair as seguintes propriedades da esperança:

$$1. \quad E[k] = k$$

$$\text{Se } g(x, y) = k \text{ é uma constante então: } E[k] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} k f(x, y) dx dy = k \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = k$$

$$2. \quad E[\alpha g(x, y) + \beta h(x, y)] = \alpha E[g(x, y)] + \beta E[h(x, y)]$$

$$E[\alpha g(x, y) + \beta h(x, y)] = \alpha \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy + \beta \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(x, y) f(x, y) dx dy$$

$$2.1. \quad E[x + y] = E[x] + E[y]$$

Momentos conjuntos:

No caso multivariado definimos os momentos por:

$$M_{kp} = E[x^k y^p] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x^k y^p f(x, y) dx dy$$

A generalização para n v.a.s é:

$$M_{k_1 k_2 \dots k_n} = E[x_1^{k_1} x_2^{k_2} \dots x_n^{k_n}] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} x_1^{k_1} x_2^{k_2} \dots x_n^{k_n} f(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n$$

Notamos imediatamente que: $M_{00} = m_{00} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$. Alguns desses momentos possuem

nomes específicos:

$$M_{10} = \mu_x = E[x] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x f(x, y) dx dy = \int_{-\infty}^{\infty} x f_x(x) dx$$

$$M_{01} = \mu_y = E[y] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y f(x, y) dx dy = \int_{-\infty}^{\infty} y f_y(y) dy$$

Com eles podemos definir os momentos centrados por:

$$m_{kp} = E\left[(x - \mu_x)^k (y - \mu_y)^p\right] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_x)^k (y - \mu_y)^p f(x, y) dx dy$$

Novamente percebe-se que: $m_{00} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$ e que:

$$m_{10} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_x) f(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x f(x, y) dx dy - \mu_x \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy$$

$m_{10} = \mu_x - \mu_x 1 = 0$, da mesma forma que $m_{01} = 0$.

Os momentos centrados com nomes específicos são as variâncias:

$$V(x) = \sigma_x^2 = m_{20} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_x)^2 f(x, y) dx dy$$

$$V(y) = \sigma_y^2 = m_{02} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (y - \mu_y)^2 f(x, y) dx dy$$

e a covariância:

$$\text{cov}(x, y) = m_{11} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_x)(y - \mu_y) f(x, y) dx dy$$

Nota-se então que:

$$V(x) = \text{cov}(x, x) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_x)^2 f(x, y) dx dy$$

$$V(y) = \text{cov}(y, y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (y - \mu_y)^2 f(x, y) dx dy.$$

A covariância tem as seguintes propriedades:

$$1. \quad \text{cov}(x_1, x_2) = \text{cov}(x_2, x_1) \text{ pois } (x_1 - \mu_1)(x_2 - \mu_2) = (x_2 - \mu_2)(x_1 - \mu_1)$$

$$2. \quad \text{cov}(x_1 + x_2, x_3) = \text{cov}(x_1, x_3) + \text{cov}(x_2, x_3), \text{ pois:}$$

$$(x_1 + x_2 - \mu_1 - \mu_2)(x_3 - \mu_3) = (x_1 - \mu_1)(x_3 - \mu_3) + (x_2 - \mu_2)(x_3 - \mu_3)$$

$$3. \quad \text{cov}(x, y) = E[xy] - E[x]E[y]$$

$$\text{cov}(x, y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_x)(y - \mu_y) f(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (xy - \mu_x y - \mu_y x + \mu_y \mu_x) f(x, y) dx dy$$

$$\text{cov}(x, y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f(x, y) dx dy - \mu_x \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} y f(x, y) dx dy +$$

$$- \mu_y \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x f(x, y) dx dy + \mu_y \mu_x \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy$$

$$\text{cov}(x, y) = E[xy] - \mu_x E[y] - \mu_y E[x] + \mu_y \mu_x$$

$$\text{cov}(x, y) = E[xy] - \mu_x \mu_y - \mu_y \mu_x + \mu_y \mu_x = E[xy] - \mu_x \mu_y = E[xy] - E[x]E[y]$$

$$4. \quad \text{cov}(\alpha x, \beta y) = \alpha \beta \text{cov}(x, y)$$

$$\text{cov}(\alpha x, \beta y) = E[\alpha \beta xy] - E[\alpha x]E[\beta y] = \alpha \beta E[xy] - \alpha \beta E[x]E[y] = \alpha \beta (E[xy] - E[x]E[y])$$

$$5. \quad \text{cov}(x, k) = 0 \text{ onde } k \text{ é uma constante.}$$

$$\text{cov}(x, k) = E[kx] - E[x]E[k] = kE[x] - kE[x] = 0$$

Essas propriedades dão origem as seguintes propriedades da variância:

$$1. \quad V(x) = E[x^2] - (E[x])^2 \text{ pois } V(x) = \text{cov}(x, x) = E[x^2] - E[x]E[x]$$

$$2. \quad V[kx] = k^2 V[x] \text{ pois } V[kx] = \text{cov}(kx, kx) = k^2 \text{cov}(x, x)$$

$$3. \quad V[\alpha + \beta x] = \beta^2 V[x]$$

$$V[\alpha + \beta x] = \text{cov}(\alpha + \beta x, \alpha + \beta x) = \text{cov}(\alpha, \alpha + \beta x) + \text{cov}(\beta x, \alpha) + \text{cov}(\beta x, \beta x) = \beta^2 \text{cov}(x, x)$$

$$4. \quad V[\alpha x + \beta y] = \alpha^2 V[x] + \beta^2 V[y] + 2\alpha\beta \text{cov}(x, y)$$

$$\text{Corolário: } V[x \pm y] = V[x] + V[y] \pm 2\text{cov}(x, y)$$

$$\begin{aligned} V[\alpha x + \beta y] &= \text{cov}(\alpha x + \beta y, \alpha x + \beta y) = \text{cov}(\alpha x, \alpha x) + \text{cov}(\alpha x, \beta y) + \\ &+ \text{cov}(\beta y, \alpha x) + \text{cov}(\beta y, \beta y) = \alpha^2 \text{cov}(x, x) + \alpha\beta \text{cov}(x, y) + \alpha\beta \text{cov}(y, x) + \beta^2 \text{cov}(y, y) = \\ &= \alpha^2 \text{cov}(x, x) + 2\alpha\beta \text{cov}(x, y) + \beta^2 \text{cov}(y, y) \end{aligned}$$

Matriz de variância-covariância:

Definindo a matriz $n \times n$: $V_{ij} = \text{cov}(x_i, x_j)$, como a matriz de variância-covariância percebe-se que os termos da diagonal são as variâncias de cada v.a. específica.

Propriedades da matriz de variância-covariância:

Nota: com os dados reais só podemos calcular a matriz $V_{ij} = \frac{1}{n} \sum_k (x_{ik} - \bar{x}_i)(x_{jk} - \bar{x}_j)$, onde x_{ik} foi o valor da k -ésima observação da v.a. x_i e $\bar{x}_i = \frac{1}{n} \sum_k x_{ik}$, em lugar da matriz

$$V_{ij} = E[(x_i - \mu_i)(x_j - \mu_j)]. \text{ Ou seja estamos substituindo a operação esperança } E[Q] \rightarrow \frac{1}{n} \sum_k Q_k.$$

Nesse caso $\bar{Q} = \frac{1}{n} \sum_k Q_k$ é um estimador de $E[Q]$ que só seria matematicamente idêntico se a média

fosse tomada com infinitos pontos, impossível na prática. Entretanto, esse fato não muda as propriedades da

matriz de variância-covariância, quer sejam definidas como $V_{ij} = \frac{1}{n} \sum_k (x_{ik} - \bar{x}_i)(x_{jk} - \bar{x}_j)$ ou

$$V_{ij} = E[(x_i - \mu_i)(x_j - \mu_j)].$$

1. É simétrica: $V_{ij} = V_{ji}$
2. É uma matriz definida positiva [Ver apêndice de matrizes]:

Uma matriz é definida positiva se para qualquer vetor \vec{h} não nulo o produto:

$$\vec{h}^T M \vec{h} = (h_1, h_2, \dots, h_n) M \begin{pmatrix} h_1 \\ h_2 \\ \vdots \\ h_n \end{pmatrix} = \sum_i \sum_j M_{ij} h_i h_j > 0, \text{ é positivo.}$$

Prova: considere $z = \sum_i h_i (x_i - \mu_i) \neq 0$. Obviamente que $z = \sum_j h_j (x_j - \mu_j)$ e que

$$z^2 = \sum_i \sum_j (x_i - \mu_i)(x_j - \mu_j) h_i h_j > 0. \text{ Então, o fato de que } E[z^2] > 0, \text{ implica que}$$

$$\sum_i \sum_j E[(x_i - \mu_i)(x_j - \mu_j)] h_i h_j = \sum_i \sum_j V_{ij} h_i h_j > 0$$

Variáveis aleatórias independentes:

Se os eventos $\{x_v \in A\}$ e $\{y_v \in B\}$ são independentes então

$$P[\{\{x_v \in A\}\{y_v \in B\}\}] = P[\{x_v \in A\}] P[\{y_v \in B\}]. \text{ Neste caso então:}$$

$$F(x, y) = F_x(x) F_y(y) \text{ e } f(x, y) = f_x(x) f_y(y)$$

Experimentos independentes:

Suponha que o espaço dos eventos da v.a. x seja Ω_x e o espaço da v.a. y seja Ω_y , e que ao realizar um experimento conjunto, cujos eventos pertencem ao espaço amostral $\Omega = \Omega_x \times \Omega_y$, o resultado de um não interfere no outro. Matematicamente estamos afirmando que:

$$x(\omega_1, \omega_2) = x(\omega_1) \text{ e } y(\omega_1, \omega_2) = y(\omega_2)$$

Então as v.a.s x e y são independentes.

Exemplo de v.a.s independentes: lançar dois dados de cores diferentes simultaneamente e definir x como o resultado de uma cor e y como o resultado da outra cor. O resultado de um dado não interfere no resultado do outro dado.

Exemplo de v.a.s não independentes: pintar metade das faces de um dado de uma cor e a outra metade de outra cor. Nesse a cor e a numeração do dado estão associadas e o resultado numérico interfere no resultado da cor. Por exemplo se o resultado para x foi 1, o resultado para y jamais poderá ser 1.

Teorema 1: Se x e y são independentes, então $g(x)$ e $h(y)$ também são independentes.

Prova: se $\{x_v \in A\}$ e $\{y_v \in B\}$ são independentes, quaisquer dois sub-conjuntos de $\{x_v \in A\}$ e $\{y_v \in B\}$ serão independentes. Assim $\{g(x) \leq g\} \subset \{x_v \in A\}$ e $\{h(y) \leq h\} \subset \{y_v \in B\}$ é a condição para poder calcular as funções $g(x)$ e $h(y)$. Portanto se x e y são independentes, então \forall $g(x)$ e $h(y)$ são independentes.

Teorema 2. Se x e y são independentes, então $E[xy] = E[x]E[y]$.

$$E[xy] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xy f_x(x) f_y(y) dx dy = \left[\int_{-\infty}^{\infty} x f_x(x) dx \right] \left[\int_{-\infty}^{\infty} y f_y(y) dy \right]$$

Teorema 3. Se x e y são independentes, então $\text{cov}(x, y) = 0$.

$$\text{cov}(x, y) = E[xy] - E[x]E[y] = E[x]E[y] - E[x]E[y] = 0$$

A covariância, portanto, nos fornece alguma informação sobre a independência entre v.a.s. Se $\text{cov}(x, y) = 0$ então x e y são independentes. O que ocorre se $\text{cov}(x, y) > 0$ ou $\text{cov}(x, y) < 0$?

Note que os produtos $(x - \mu_x)(y - \mu_y)$ e $(x - \bar{x})(y - \bar{y})$ em um gráfico $(x - \mu_x)$ vs $(y - \mu_y)$ ou $(x - \bar{x})$ vs $(y - \bar{y})$ serão positivos no primeiro e terceiro quadrantes, $++$ e $--$, e negativos no segundo e quarto quadrantes, $-+$ e $-$.

A figura xxx (a) mostra uma nuvem de pontos com uma concentração maior de pontos no primeiro e terceiro quadrantes, terá $\sum_i (x_i - \bar{x})(y_i - \bar{y})$ positiva, ou seja, com uma covariância positiva. Percebe-se dessa nuvem que a v.a. y tende a crescer quando a v.a. x cresce, e a decrescer quando x decresce. O espalhamento da nuvem informa que essa tendência não é perfeita é que existe algum grau de independência estatística da v.a. y em relação à v.a. x . Nesse caso afirmamos que as v.a.s x e y são positivamente correlacionadas. O gráfico da figura xxx(b) mostra o caso em que $y = x$, totalmente dependente, ou totalmente correlacionadas, e se percebe a reta perfeita em que nenhum dos pontos se desvia da reta.

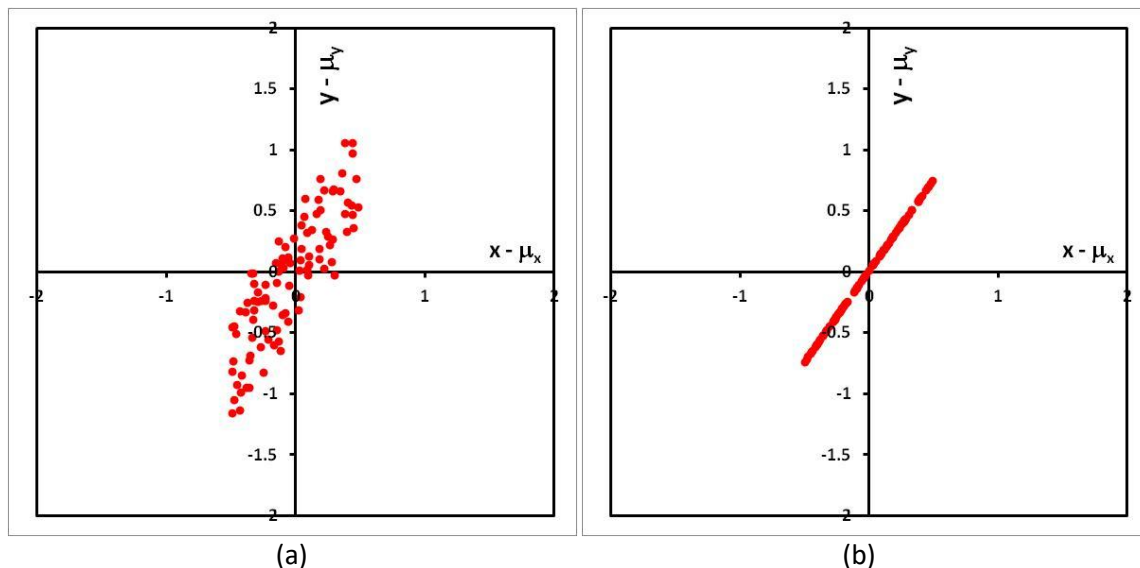


Figura xxx. (a) caso de duas variáveis positivamente, mas não perfeitamente, correlacionadas. (b) Caso de duas variáveis positivamente e perfeitamente correlacionadas.

Já a figura xxx (a) mostra uma nuvem de pontos com uma concentração maior de pontos nos segundo e quarto quadrantes, com $\sum_i (x_i - \bar{x})(y_i - \bar{y})$ negativa, ou seja, com uma covariância negativa. Percebe-se dessa nuvem que a v.a. y tende a decrescer quando a v.a. x cresce, e a crescer quando x decresce. Nessa situação afirmamos que as v.a.s x e y são negativamente correlacionadas. O gráfico da figura xxx(b) mostra o caso

em que $y = -x$, perfeitamente anti-correlacionada, em que nenhum dos pontos se desvia da reta negativamente inclinada.

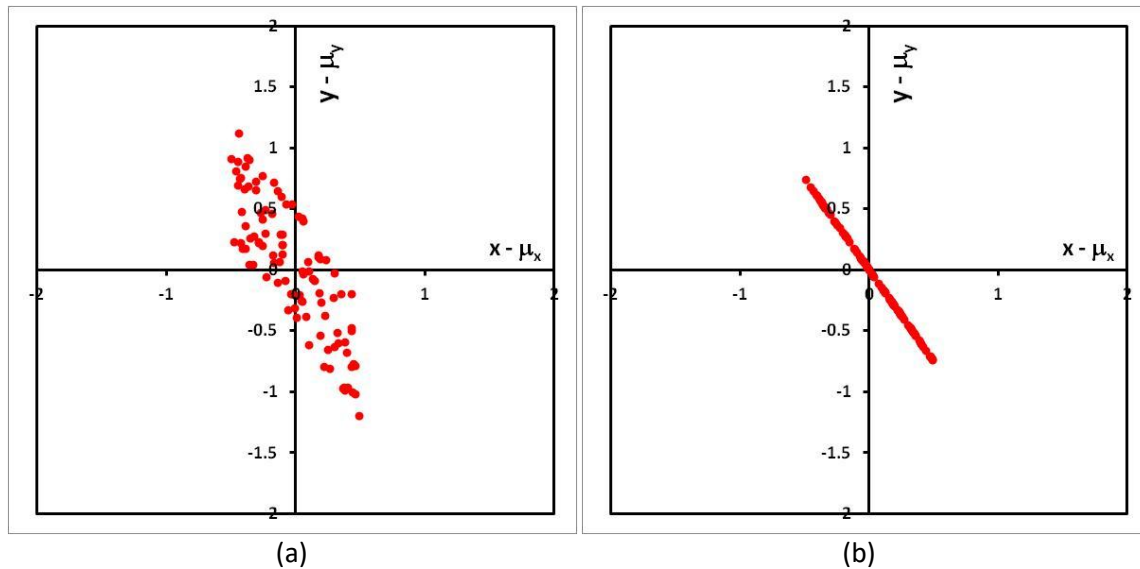


Figura xxx. (a) caso de duas variáveis positivamente, mas não perfeitamente, correlacionadas. (b) Caso de duas variáveis positivamente e perfeitamente correlacionadas.

Se as v.a.s são independentes então a núvem se espalha igualmente pelos quatro quadrantes levando a

$$\sum_i (x_i - \bar{x})(y_i - \bar{y}) = 0 \text{ como mostra a figura xxx.}$$




Figura xxx. Caso de duas variáveis descorrelacionadas.

Coeficiente de Correlação:

A medida da covariância como uma medida da independência entre duas v.a.s, entretanto, apresenta alguns problemas. Primeiro trata-se de uma medida com dimensão, $\dim[\text{cov}(x, y)] = \dim[x]\dim[y]$. Se x e y têm dimensão de distância, ou massa, por exemplo, a covariância terá dimensão de área, ou massa ao quadrado. Precisamos de uma grandeza adimensional relacionada à covariância para ser utilizada como um grau de independência entre v.a.s. Então vamos construir o coeficiente de correlação adimensional definido por:

$$r_{xy} = r[x, y] = \frac{\text{cov}(x, y)}{\sqrt{\text{cov}(x, x)}\sqrt{\text{cov}(y, y)}} = \frac{\text{cov}(x, y)}{\sqrt{V[x]}V[y]}$$

Com essa definição ganhamos mais do que simplesmente a obtenção de uma grandeza adimensional porque podemos mostrar que se trata de um número que varia entre +1 e -1, com zero significando independência estatística, +1 correlação positiva perfeita e -1 correlação negativa, ou anti-correlação, perfeita.

Teorema do coeficiente de correlação: $-1 \leq r_{xy} \leq 1$.

Prova usando a desigualdade de Schwartz:

$$E\left\{\left[\lambda(x - \mu_x) - (y - \mu_y)\right]^2\right\} \geq 0 \quad \forall \lambda \in \mathbb{R} \text{ pois se trata da esperança de uma quantidade positiva.}$$

Desenvolvendo o quadrado temos:

$$\left[\lambda(x - \mu_x) - (y - \mu_y)\right]^2 = \lambda^2(x - \mu_x)^2 - 2\lambda(x - \mu_x)(y - \mu_y) + (y - \mu_y)^2$$

Logo

$$E\left\{\left[\lambda(x - \mu_x) - (y - \mu_y)\right]^2\right\} = \lambda^2 E\left[(x - \mu_x)^2\right] - 2\lambda E\left[(x - \mu_x)(y - \mu_y)\right] + E\left[(y - \mu_y)^2\right]$$

que pode ser escrito em termos das variâncias e covariâncias como:

$$E\left\{\left[\lambda(x - \mu_x) - (y - \mu_y)\right]^2\right\} = \lambda^2 V[x] - 2\lambda \text{cov}(x, y) + V[y]$$

Isso nos leva à desigualdade da equação quadrática em λ dada por:

$$V[x]\lambda^2 - 2\text{cov}(x, y)\lambda + V[y] \geq 0 \text{ com } V[x] > 0 \text{ e } V[y] > 0$$

A desigualdade $a\lambda^2 + b\lambda + c \geq 0$ com $a > 0$ só pode ser satisfeita se $a\lambda^2 + b\lambda + c = 0$ não admite raízes reais ou apenas uma raiz que toca o eixo x . Essa condição implica que $b^2 - 4ac \leq 0$. Agora fazendo $a = V[x]$, $b = -2\text{cov}(x, y)$ e $c = V[y]$ percebe-se que $4\text{cov}^2(x, y) - 4V[x]V[y] \leq 0$ ou seja,

$$\frac{\text{cov}^2(x, y)}{V[x]V[y]} \leq 1 \text{ que implica em } -1 \leq \frac{\text{cov}(x, y)}{\sqrt{V[x]V[y]}} \leq 1.$$

Esse teorema pode ser generalizado e utilizado para definir ortogonalidade entre v.a.s.

Teorema generalizado para independência entre v.a.s:
$$-1 \leq \frac{E[xy]}{\sqrt{E[x^2]E[y^2]}} \leq 1.$$

Basta fazer o mesmo começando com $E[(\lambda x - y)^2] \geq 0$ que nos leva diretamente à

$$E[x^2]\lambda^2 - 2E[xy]\lambda + E[y^2] \geq 0 \text{ e, conseqüentemente, a } -1 \leq \frac{E[xy]}{\sqrt{E[x^2]E[y^2]}} \leq 1. \text{ O fato}$$

de que esse é um número entre -1 e +1 significa que sempre existirá um ângulo θ para o qual

$$E[xy] = \sqrt{E[x^2]}\sqrt{E[y^2]} \cos \theta. \text{ Se definimos } x_{RMS} = \sqrt{E[x^2]}, \text{ ou seja root-mean-square,}$$

porque utilizamos $\sqrt{\left(\frac{1}{n} \sum_k x_k^2\right)}$ como estimador de $\sqrt{E[x^2]}$, podemos afirmar então que:

$$E[xy] = x_{RMS} y_{RMS} \cos \theta \text{ ou } \cos \theta = \frac{E[xy]}{x_{RMS} y_{RMS}}$$

Em que o cosseno mede o grau de relação entre as v.a.s x e y . Se $E[xy] = 0$, mas $E[x^2] \neq 0$ e

$E[y^2] \neq 0$ então $\theta = \frac{\pi}{2} = 90^\circ$ e dizemos que x e y são ortogonais entre si, ou seja, $x \perp y$.

Espaços métricos e distância de correlação:

Um espaço é métrico se existe uma função distância $d(x, y): E \times E \rightarrow \mathbb{R}$ para $\forall x, y \in E$ satisfazendo aos axiomas:

1. Desigualdade triangular: $d(x, z) \leq d(x, y) + d(y, z)$
2. Se $d(x, y) = 0$ então $x = y$
3. $d(x, y) = d(y, x)$

Com esses axiomas podemos demonstrar o teorema:

a. $d(x, y) \geq 0$

Fazer $z = x$ no axioma 1: $d(x, x) \leq d(x, y) + d(y, x)$ usando os axiomas (2) e (3) $2d(x, y) \geq 0$, logo $d(x, y) \geq 0$.

Então a função distância deve ser um número real e positivo. Se essa função existe então ela é a métrica do espaço e podemos medir distâncias entre os elementos do conjunto E . Nesse caso dizemos que o espaço é métrico.

Distância Euclidiana:

A distância Euclidiana entre os vetores $\vec{x} = (x_1, x_2, \dots, x_n)$ e $\vec{y} = (y_1, y_2, \dots, y_n)$ é definida como

$$d(\vec{x}, \vec{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2} = \sqrt{\sum_{j=1}^n (x_j - y_j)^2} \quad \text{que já apresenta}$$

naturalmente as propriedades $d(\vec{x}, \vec{y}) \geq 0$ e $d(\vec{x}, \vec{y}) = d(\vec{y}, \vec{x})$. Notamos que

$d(\vec{x}, \vec{y}) = \sqrt{(\vec{x} - \vec{y}) \cdot (\vec{x} - \vec{y})}$ onde o produto escalar entre dois vetores é definido da forma anterior como $\vec{a} \cdot \vec{b} = \sum_j a_j b_j$.

Falta mostrar o axioma 1:

$$d(x, z) \leq d(x, y) + d(y, z)$$

$$\begin{aligned} d^2(\vec{x}, \vec{z}) &= \sum_j (x_j - z_j)^2 = \sum_j (x_j - y_j + y_j - z_j)^2 = \\ &= \sum_j \left[(x_j - y_j)^2 + 2(x_j - y_j)(y_j - z_j) + (y_j - z_j)^2 \right] = \\ &= \sum_j (x_j - y_j)^2 + \sum_j (y_j - z_j)^2 + 2 \sum_j (x_j - y_j)(y_j - z_j) \end{aligned}$$

$$d^2(\vec{x}, \vec{z}) = d^2(\vec{x}, \vec{y}) + d^2(\vec{y}, \vec{z}) + 2(\vec{x} - \vec{y}) \cdot (\vec{y} - \vec{z})$$

Agora usamos o fato de que $-1 \leq \frac{\vec{a} \cdot \vec{b}}{\sqrt{(\vec{a} \cdot \vec{a})(\vec{b} \cdot \vec{b})}} \leq +1$ para perceber que

$$(\vec{x} - \vec{y}) \cdot (\vec{y} - \vec{z}) \leq \sqrt{(\vec{x} - \vec{y}) \cdot (\vec{x} - \vec{y})} \sqrt{(\vec{y} - \vec{z}) \cdot (\vec{y} - \vec{z})}, \quad \text{ou} \quad \text{seja,}$$

$$(\vec{x} - \vec{y}) \cdot (\vec{y} - \vec{z}) \leq d(\vec{x}, \vec{y}) d(\vec{y}, \vec{z}). \text{ Nesse caso:}$$

$$d^2(\vec{x}, \vec{z}) \leq d^2(\vec{x}, \vec{y}) + 2d(\vec{x}, \vec{y})d(\vec{y}, \vec{z}) + d^2(\vec{y}, \vec{z}) = [d(\vec{x}, \vec{y}) + d(\vec{y}, \vec{z})]^2$$

$$\text{Logo: } d(\vec{x}, \vec{z}) \leq d(\vec{x}, \vec{y}) + d(\vec{y}, \vec{z}).$$

Essa não é a única distância possível. Existem outras distâncias como a distância Manhattan

$$d_{xy} = \sum_j |x_j - y_j|. \text{ É chamada de distância Manhattan, ou distância do motorista de Taxi, taxicab distance,}$$

porque em uma cidade quadriculada o motorista nunca pode tomar o caminho da hipotenusa, como mostra a figura xxx abaixo extraída da wikipedia:

[http://upload.wikimedia.org/wikipedia/commons/0/08/Manhattan_distance.svg].




Figura xxx. Manhattan distance. Note que as distâncias vermelha, azul e amarela são iguais.

Em lugar de somar os quadrados das diferenças o motorista tem que somar os módulos das diferenças nas duas dimensões.

Distância p-ádica:

Kurt Hensel em 1897 introduziu a noção dos números p-ádicos. Seja x um inteiro e p um número primo, então: $x = a_0 + a_1p + a_2p^2 + \dots + a_kp^k$ com $0 \leq a_k \leq p-1$.

Exemplo: $x = 23$ e $p = 2$. Nesse caso: $p^2 = 4$, $p^3 = 8$, $p^4 = 16$ e $p^5 = 32 > 23$ já não interessa mais. Assim começamos da potência mais alta e vamos descendo: $23 - 16 = 7$, $7 - 4 = 3$ e $3 - 2 = 1$, logo: $x = 1 \times 2^0 + 1 \times 2^1 + 1 \times 2^2 + 1 \times 2^4 = 1 + 2 + 4 + 16 = 23$.

Vamos tomar agora $p = 3$, então $p^2 = 9$ e $p^3 = 27 > 23$. Nesse caso $23 - 9 = 14$, $14 - 9 = 5$, $23 - 2 \times 9 = 5$, $5 - 3 = 2$, logo $x = 2 \times 3^0 + 1 \times 3^1 + 2 \times 3^2 = 2 + 3 + 18 = 23$.

Qualquer inteiro positivo pode ser escrito como:

$$x = \sum_{j=0}^{\infty} a_j p^j \rightarrow 0 \leq a_j \leq p-1 \text{ e } p \text{ um número primo.}$$

O que acontece se permitimos j negativos? Teríamos também $\frac{1}{p}$, $\frac{1}{p^2}$ etc e assim poderíamos escrever

qualquer número racional como: $x = \sum_{j=r}^{\infty} a_j p^j$ com $r \in \mathbb{Z}$, logo r pode ser negativo. Note dessa definição

então que x é divisível por p^r , então p^r é a maior potência divisora de x . A distância p-ádica é definida como: $|x|_p = p^{-r}$.

Exemplos:

$$1. \quad |20|_2 = ?. \quad 20 = 2^2 \times 5 = 2^2 \times [1 + 2^2] = 2^2 + 2^4 = \sum_{j=2}^{\infty} a_j p^j \quad \text{com} \quad a_2 = 1, \quad a_3 = 0,$$

$$a_4 = 1 \text{ e } a_{j>4} = 0. \text{ Neste caso } |20|_2 = \frac{1}{2^2} = \frac{1}{4} = 0.25.$$

$$2. \quad \text{O número ZERO é divisível por qualquer número, portanto } |0|_p = \frac{1}{p^{\infty}} = 0.$$

Operações adição e multiplicação de números p-ádicos:

Suponha agora dois números x e y , com $x = p^{r_1} \sum_{j=0}^{\infty} a_j p^j$ e $y = p^{r_2} \sum_{k=0}^{\infty} b_k p^k$ então

$xy = p^{r_1+r_2} \sum_{j=0}^{\infty} \sum_{k=0}^{\infty} a_j b_k p^{j+k}$. Fazendo $j+k=m$, $k=m-j$ e $c_k = a_j b_{m-j}$ então podemos

escrever $xy = p^{r_1+r_2} \sum_{k=0}^{\infty} c_k p^k$. Nesse caso percebemos que $|xy|_p = \frac{1}{p^{r_1+r_2}} = \frac{1}{p^{r_1}} \frac{1}{p^{r_2}} = |x|_p |y|_p$.

Suponha agora dois números x e y , com $x = p^{r_1} \sum_{j=0}^{\infty} a_j p^j$ e $y = p^{r_2} \sum_{k=0}^{\infty} b_k p^k$ então

$$x + y = p^{r_{\min}} \left[p^{r_1-r_{\min}} \sum_{j=0}^{\infty} a_j p^j + p^{r_2-r_{\min}} \sum_{j=0}^{\infty} b_j p^j \right], \text{ onde } r_{\min} = \min\{r_1, r_2\}. \text{ O número que}$$

ficou entre colchetes $[]$ pode ser, ou não, divisível por p , ou seja $[] = p^r \sum c_k p^k$. Neste caso

$$x + y = p^{r_{\min}+r} \sum c_k p^k. \text{ Assim } |x+y|_p = \frac{1}{p^{r+r_{\min}}} \leq \frac{1}{p^{r_{\min}}} \leq \frac{1}{p^{r_1}} + \frac{1}{p^{r_2}} \text{ e } \frac{1}{p^{r_{\min}}} > \frac{1}{p^{r_{\max}}}.$$

Dessa forma $|x+y|_p \leq |x|_p + |y|_p$ como a distância, mas a distância p-ádica apresenta uma restrição maior que

é: $|x + y|_p \leq \max[|x|_p, |y|_p]$. Note que isso significa que $|x + x|_p \leq \max[|x|_p, |x|_p] \leq |x|_p$, ou seja, $|2x|_p \leq |x|_p$ em lugar do costumeiro $|2x| \geq |x|$. Em 1944 Mark Krasner criou o termo espaço ultramétrico para a distância satisfazendo aos axiomas:

1. Se $\delta(x, y) = 0$ então $x = y$
2. $\delta(x, y) = \delta(y, x)$
3. $\delta(x, z) \leq \max[\delta(x, y), \delta(y, z)]$

Um espaço que satisfaz à esses axiomas é chamado de ultramétrico. Note que se trocou a desigualdade triangular pela desigualdade do máximo.

Com a distância Euclidiana podemos definir uma distância de correlação.

Suponha as v.a.s x e y , com $\bar{x} = \frac{1}{N} \sum_j x_j$, $s_x^2 = \frac{1}{N} \sum_j (x_j - \bar{x})^2$, $\bar{y} = \frac{1}{N} \sum_j y_j$,

$s_y^2 = \frac{1}{N} \sum_j (y_j - \bar{y})^2$, em que \bar{x} e s_x^2 são os estimadores de $\mu_x = E[x]$ e de $\sigma_x^2 = V(x)$ e \bar{y} e s_y^2

os estimadores de $\mu_y = E[y]$ e $\sigma_y^2 = V(y)$. A covariância será dada por

$\text{cov}(x, y) = \frac{1}{N} \sum_j (x_j - \bar{x})(y_j - \bar{y})$ e o coeficiente de correlação $r_{xy} = \frac{\text{cov}(x, y)}{s_x s_y}$. Algebricamente

vemos que:

$$s_x^2 = \frac{1}{N} \sum_j (x_j^2 - 2\bar{x}x_j + \bar{x}^2) = \frac{1}{N} \sum_j x_j^2 - 2\bar{x} \frac{1}{N} \sum_j x_j + \bar{x}^2 \frac{1}{N} \sum_j 1 = \frac{1}{N} \sum_j x_j^2 - 2\bar{x} \bar{x} + \bar{x}^2 \frac{1}{N} N$$

$$s_x^2 = \frac{1}{N} \sum_j x_j^2 - \bar{x}^2 = \overline{x^2} - \bar{x}^2$$

Agora vamos definir as v.a.s padronizadas $z_j = \frac{x_j - \bar{x}}{\sqrt{N} s_x}$ e $s_j = \frac{y_j - \bar{y}}{\sqrt{N} s_y}$. Notamos que

$$\sum_j z_j = \frac{1}{\sqrt{N} s_x} \sum_j (x_j - \bar{x}) = \frac{1}{\sqrt{N} s_x} \left[\sum_j x_j - \bar{x} \sum_j 1 \right] = \frac{1}{\sqrt{N} s_x} [N \bar{x} - N \bar{x}] = 0 \quad \text{e, da mesma}$$

forma, $\sum_j s_j = 0$, que é equivalente ao fato de que $E[x - \mu] = 0$. Por outro lado

$$\sum_j z_j^2 = \frac{1}{N s_x^2} \sum_j (x_j - \bar{x})^2 = \frac{1}{s_x^2} \left[\frac{1}{N} \sum_j (x_j - \bar{x})^2 \right] = \frac{1}{s_x^2} s_x^2, \text{ ou seja, } \sum_j z_j^2 = 1. \text{ Da mesma forma}$$

$\sum_j s_j^2 = 1$. Podemos então pensar em dois vetores unitários.

Agora vamos definir uma distância Euclidiana entre esses dois vetores unitários como:

$$d_{xy}^2 = \sum_j (z_j - s_j)^2$$

$$d_{xy}^2 = \sum_j (z_j - s_j)^2 = \sum_j z_j^2 + \sum_j s_j^2 - 2 \sum_j z_j s_j = 2 \left(1 - \sum_j z_j s_j \right)$$

Mas agora notamos que $\sum_j z_j s_j = \frac{1}{s_x s_y} \frac{1}{N} \sum_j (x_j - \bar{x})(y_j - \bar{y}) = \frac{\text{cov}(x, y)}{s_x s_y}$ logo $\sum_j z_j s_j = r_{xy}$ e:

$$d_{xy}^2 = 2(1 - r_{xy})$$

Então vemos que a grandeza $d_{xy} = \sqrt{2(1 - r_{xy})}$ se comporta como uma distância. Chamamos essa distância de distância de correlação. Como $-1 \leq r_{xy} \leq +1$ a distância de correlação varia entre $0 \leq d_{xy} \leq 2$. Quanto maior a correlação menor a distância.

Vale notar um ponto importante aqui. Para ser uma distância exigimos que se $d(x, y) = 0$ então $x = y$.

Mas $d(x, y) = 0$ significa que $r_{xy} = +1$. Duas v.a.s relacionadas da forma $x_j = a y_j + b$ com $a > 0$

apresentam correlação $r_{xy} = +1$ embora $x \neq y$. Entretanto, as duas variáveis $z_j = \frac{x_j - \bar{x}}{\sqrt{N}s_x}$ e

$s_j = \frac{y_j - \bar{y}}{\sqrt{N}s_y}$ são iguais, pois:

$$1. \quad \bar{x} = \frac{1}{N} \sum_j x_j = \frac{1}{N} \sum_j a y_j + \frac{1}{N} \sum_j b = a \frac{1}{N} \sum_j y_j + b, \text{ ou seja, } \bar{x} = a\bar{y} + b.$$

$$2. \quad s_x^2 = \frac{1}{N} \sum_j (x_j - \bar{x})^2 = \frac{1}{N} \sum_j (a y_j + b - a\bar{y} - b)^2 = a^2 \frac{1}{N} \sum_j (y_j - \bar{y})^2, \quad \text{ou seja,}$$

$$s_x^2 = a^2 s_y^2.$$

$$3. \quad z_j = \frac{x_j - \bar{x}}{\sqrt{N}s_x} = \frac{a y_j + b - a\bar{y} - b}{\sqrt{N}a s_y} = \frac{a}{a} \frac{y_j - \bar{y}}{\sqrt{N}s_y} \text{ logo } z_j = s_j.$$

Espaços ULTRAMÉTRICOS:

Partindo dos espaços métricos podemos definir um espaço ultramétrico especialmente adequado para análises de clusters e hierarquias.

Adição de v.a.s independentes: se $z = x + y$ em que x e y são v.a.s independentes com fdp's $f_x(x)$ e

$f_y(y)$, então a nova v.a. z terá a fdp dada por $f_z(z) = \int_{-\infty}^{+\infty} f_x(x) f_y(z-x) dx$.

$$\text{Prova: } F_z(z) = \iint_{x+y \leq z} f(x, y) dx dy = \int_{-\infty}^{+\infty} \int_{-\infty}^{z-x} f(x, y) dx dy = \int_{-\infty}^{+\infty} f_x(x) dx \int_{-\infty}^{z-x} f_y(y) dy$$

$$\text{Então}^1: f_z(z) = \frac{d}{dz} F_z(z) = \int_{-\infty}^{+\infty} f_x(x) dx \frac{d}{dz} \int_{-\infty}^{z-x} f_y(y) dy$$

$$f_z(z) = \int_{-\infty}^{+\infty} f_x(x) f_y(z-x) dx$$

Convolução e Correlação: A operação entre duas funções $f(x)$ e $g(x)$ definida por

$$c(z) = \int_{-\infty}^{+\infty} f(x) g(z-x) dx \text{ é tão importante que ganhou nome próprio: é chamada de CONVOLUÇÃO e é}$$

simbolizada por $c(z) = f * g$. Ela tem uma prima denominada por operação CORRELAÇÃO definida de

$$\text{forma um pouco diferente por } C(z) = f \otimes g = \int_{-\infty}^{+\infty} f(x) g(x-z) dx. \text{ Note que a diferença está no argumento}$$

da função $g(x)$, o qual na convolução é $z-x$ e na correlação é $x-z$.

Intuição sobre as operações convolução e correlação:

Note que a operação $f(x-a)$ é simplesmente transladar a função $f(x)$ no eixo horizontal pela quantidade a para a direita. Já a $f(x+a)$ translada a função para a esquerda. A figura xxx mostra a função $f(x) = e^{-x} H(x)$, preta, com a $f(x-2)$ em azul e a $f(x+2)$ em vermelho. Note que a curva azul deslocou de 2 para a direita e a vermelha de 2 para a esquerda. Já a operação $f(-x)$ significa uma reflexão

¹ Estamos usando a seguinte regra para derivar integrais: $\frac{d}{dz} \int_{r(z)}^{s(z)} f(u) du = \frac{d}{dz} [F[s(z)] - F[r(z)]]$ onde $F'(u) = f(u)$

$$\text{portanto } \frac{d}{dz} \int_{r(z)}^{s(z)} f(u) du = \frac{d}{ds} F[s(z)] \frac{ds}{dz} - \frac{d}{dr} F[r(z)] \frac{dr}{dz} \text{ ou seja } \frac{d}{dz} \int_{r(z)}^{s(z)} f(u) du = f[s(z)] \frac{ds}{dz} - f[r(z)] \frac{dr}{dz}.$$

da função em torno do eixo y . A figura xx mostra o gráfico das curvas $f(x) = e^{-x+1}H(x-1)$ e $f(-x) = e^{x-1}H(-x-1)$.




Figura xxx. Gráfico das curvas $f(x) = e^{-x}H(x)$ em preto, $f(x-2) = e^{-x+2}H(x-2)$ em azul e $f(x+2) = e^{-x-2}H(x+2)$ em vermelho.




Figura xxx. Gráfico das curvas $f(x) = e^{-x+1}H(x-1)$ em preto e $f(-x) = e^{x+1}H(-x-1)$ em vermelho.

Vamos analisar uma auto-convolução e uma auto-correlação da função $f(x)$ com ela mesma. Na auto-correlação a $f(x-z)$ é a própria função deslocada por z . Mas na auto-convolução $z-x=-(x-z)$ a função é deslocada e refletida no eixo y .




Figura xxx. Multiplicação das curvas $f(x) = e^{-x}H(x)$ por $f(z-x)$ para $z = -1; 0; 0,5; 1; 2$ e 4

A figura xxx mostra a curva da autoconvolução $c(z) = \int_{-\infty}^{+\infty} f(x)g(z-x)dx$ em função de z .




Figura xxx. Autoconvolução de $f(x) = e^{-x}H(x)$ em função de z

Já a figura xxx mostra a multiplicação de $f(x)$ por $f(x-z)$ da auto-correlação e a figura xxx o resultado da auto-correlação em função de z .




Figura xxx. Multiplicação das curvas $f(x) = e^{-x}H(x)$ por $f(x-z)$ para $z = -2; -1; 0; 1$ e 2




Figura xxx. Auto-correlação de $f(x) = e^{-x}H(x)$ em função de z

Propriedades da convolução:

$$1. \quad f * g = g * f$$

Prova: $g * f = \int_{-\infty}^{+\infty} f(z-x)g(x)dx$. Fazendo a mudança de variável $z-x=u$,

$$g * f = -\int_{+\infty}^{-\infty} f(u)g(z-u)du = \int_{-\infty}^{+\infty} f(u)g(z-u)du = f * g. \quad \text{Note que } f \otimes g \neq g \otimes f, \quad \text{pois}$$

$$\int_{-\infty}^{+\infty} f(x)g(x-z)dx = \int_{-\infty}^{+\infty} f(x+z)g(x)dx \neq \int_{-\infty}^{+\infty} f(x-z)g(x)dx.$$

2. A propriedade distributiva frente à adição $f * (g+h) = f * g + f * h$ é trivial.

3. Propriedade distributiva frente à convolução: $f * (g * h) = (f * g) * h$.

Prova: $f * (g * h) = \int_{-\infty}^{+\infty} f(x)g * h(x-z)dx$ e $g * h(z-x) = \int_{-\infty}^{+\infty} g(u)h(z-x-u)du$, então

$$f * (g * h) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x)g(u)h(z-x-u)dxdu. \quad \text{Por outro lado:}$$

$$(f * g) * h = \int_{-\infty}^{+\infty} f * g(x) h(z-x) dx = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(u) g(x-u) h(z-x) dx du .$$

Fazendo $w = x - u$, $x = w + u$ e $dw = dx$ temos que:

$$(f * g) * h = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(u) g(w) h(z-w-u) dw du .$$

Chamando $w = u$ e $u = x$ temos $(f * g) * h = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x) g(u) h(z-x-u) dx du = f * (g * h)$.

FGM e Função Característica de v.a.s independentes:

Se as v.a.s x e y são independentes então $E[xy] = E[x]E[y]$. Nesse caso então

$$M_{x+y}(t) = E[e^{(x+y)t}] = E[e^{xt} e^{yt}] = E[e^{xt}] E[e^{yt}] = M_x(t) \times M_y(t)$$

Da mesma forma:

$$\varphi_{x+y}(t) = E[e^{i(x+y)t}] = E[e^{ixt} e^{iyt}] = E[e^{ixt}] E[e^{iyt}] = \varphi_x(t) \times \varphi_y(t)$$

Ou seja a função geradora dos momentos e a função característica da v.a. $z = x + y$ serão os produtos das respectivas funções de cada uma das v.a.s.

Teorema da convolução: Daqui podemos extrair o teorema da convolução afirmando que:

$$\text{Sejam: } \varphi_x(t) = \int_{-\infty}^{+\infty} e^{ixt} f_x(x) dx; \varphi_y(t) = \int_{-\infty}^{+\infty} e^{iyt} f_y(y) dy \text{ e } f_z(z) = \int_{-\infty}^{+\infty} f_x(x) f_y(z-x) dx .$$

$$\text{Então } \varphi_z(t) = \int_{-\infty}^{+\infty} e^{izt} f_z(z) dz \text{ é dado por } \varphi_z(t) = \varphi_x(t) \varphi_y(t) .$$

O teorema da convolução é demonstrado também de outra forma e discutido com mais profundidade no apêndice xxx.

FGM e Função Característica conjuntas:

$$M(t_1, t_2) = E\left[e^{xt_1 + yt_2}\right] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{xt_1 + yt_2} f(x, y) dx dy$$

$$\varphi(t_1, t_2) = E\left[e^{ixt_1 + iyt_2}\right] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{ixt_1 + iyt_2} f(x, y) dx dy$$

Relações com os momentos: sabemos que $e^{xt_1 + yt_2} = \sum_{n=0}^{\infty} \frac{(xt_1 + yt_2)^n}{n!}$. Por outro lado

$$(xt_1 + yt_2)^n = \sum_{k=0}^n \frac{n!}{k!(n-k)!} x^k t_1^k y^{n-k} t_2^{n-k}.$$

$$\text{Então } E\left[e^{xt_1 + yt_2}\right] = \sum_{n=0}^{\infty} \sum_{k=0}^n \frac{1}{n!} \binom{n}{k} E\left[x^k y^{n-k}\right] t_1^k t_2^{n-k}$$

$$\text{Portanto } M(t_1, t_2) = \sum_{n=0}^{\infty} \sum_{k=0}^n \frac{1}{n!} \binom{n}{k} M_{k, n-k} t_1^k t_2^{n-k}$$

$$\text{Claro então que } \varphi(t_1, t_2) = \sum_{n=0}^{\infty} \sum_{k=0}^n \frac{i^n}{n!} \binom{n}{k} M_{k, n-k} t_1^k t_2^{n-k}$$

A série de Taylor multivariada é dada por:

$$\begin{aligned} f(x, y) &= \sum_{n=0}^{\infty} \frac{1}{n!} \left[(x\partial_x + y\partial_y)^n f(x, y) \right]_{(x,y)=(0,0)} = \\ &= \sum_{n=0}^{\infty} \sum_{k=0}^n \frac{1}{n!} \frac{n!}{k!(n-k)!} x^k y^{n-k} \left[\frac{\partial^n}{\partial x^k \partial y^{n-k}} f(x, y) \right]_{(x,y)=(0,0)} = \\ &= \sum_{n=0}^{\infty} \frac{1}{n!} \left[\sum_{k=0}^n \frac{n!}{k!(n-k)!} (x^k \partial_x^k + y^{n-k} \partial_y^{n-k}) f(x, y) \right]_{(x,y)=(0,0)} \end{aligned}$$

$$f(x, y) = \sum_{n=0}^{\infty} \sum_{k=0}^n \frac{1}{n!} \binom{n}{k} x^k y^{n-k} \left[\frac{\partial^n f(x, y)}{\partial x^k \partial y^{n-k}} \right]_{(x,y)=(0,0)}$$

$$\text{Nesse caso } M(t_1, t_2) = \sum_{n=0}^{\infty} \sum_{k=0}^n \frac{1}{n!} \binom{n}{k} \left[\frac{\partial^n M(t_1, t_2)}{\partial t_1^k \partial t_2^{n-k}} \right]_{(t_1, t_2)=(0,0)} t_1^k t_2^{n-k}$$

$$\text{Comparando com a expansão dos momentos vemos que } M_{k,n-k} = \frac{\partial^n M(t_1, t_2)}{\partial t_1^k \partial t_2^{n-k}} \bigg|_{(t_1, t_2)=(0,0)} \text{ e que}$$

$$M_{k,n-k} = \frac{1}{i^n} \frac{\partial^n \varphi(t_1, t_2)}{\partial t_1^k \partial t_2^{n-k}} \bigg|_{(t_1, t_2)=(0,0)}.$$

Produto de v.a.s independentes: se $z = xy$ em que x e y são v.a.s independentes com fdp's $f_x(x)$ e

$$f_y(y), \text{ então a nova v.a. } z \text{ terá a fdp dada por } f(z) = \int_{-\infty}^{\infty} \frac{1}{|x|} f_x(x) f_y\left(\frac{z}{x}\right) dx.$$

Prova: Note que $xy \leq z$ pode ser escrito como $y \geq \frac{z}{x}$ se $x < 0$ ou $y \leq \frac{z}{x}$ se $x > 0$. Então

$$F(z) = P[xy \leq z] = P\left[y \geq \frac{z}{x} \mid x < 0\right] + P\left[y \leq \frac{z}{x} \mid x > 0\right]$$

$$F(z) = \int_{-\infty}^0 f_x(x) dx \int_{\frac{z}{x}}^{+\infty} f_y(y) dy + \int_0^{\infty} f_x(x) dx \int_{-\infty}^{\frac{z}{x}} f_y(y) dy$$

Então:

$$f(z) = \frac{dF}{dz} = \int_{-\infty}^0 f_x(x) dx \frac{d}{dz} \int_{\frac{z}{x}}^{+\infty} f_y(y) dy + \int_0^{\infty} f_x(x) dx \frac{d}{dz} \int_{-\infty}^{\frac{z}{x}} f_y(y) dy$$

$$f(z) = \frac{dF}{dz} = \int_{-\infty}^0 f_x(x) dx \left(-\frac{1}{x}\right) f_y\left(\frac{z}{x}\right) dx + \int_0^{\infty} f_x(x) \left(\frac{1}{x}\right) f_y\left(\frac{z}{x}\right) dx$$

$$f(z) = \int_{-\infty}^{\infty} \frac{1}{|x|} f_x(x) f_y\left(\frac{z}{x}\right) dx$$

Quociente: se $z = x + y$ em que x e y são v.a.s independentes com fdp's $f_x(x)$ e $f_y(y)$, então a nova v.a. $z = xy$ terá a fdp dada por $f(z) = \int_{-\infty}^{\infty} \frac{1}{|x|} f_x(x) f_y\left(\frac{z}{x}\right) dx$.

Note que a fdp do quociente $z = \frac{x}{y}$ agora muda para $y \geq zx$ se $x < 0$ ou $y \leq zx$ se $x > 0$.

$$\text{Então } F(z) = P\left[\frac{x}{y} \leq z\right] = P[y \geq zx | x < 0] + P[y \leq zx | x > 0]$$

$$F(z) = \int_{-\infty}^0 \int_{zx}^{+\infty} f_x(x) f_y(y) dx dy + \int_0^{\infty} \int_{-\infty}^{zx} f_x(x) f_y(y) dx dy$$

$$f(z) = \frac{dF}{dz} = \int_{-\infty}^0 -x f_x(x) f_y(zx) dx + \int_0^{\infty} x f_x(x) f_y(zx) dx$$

$$f(z) = \int_{-\infty}^{\infty} |x| f_x(x) f_y(zx) dx$$

Apêndice XX: Mudança de coordenadas e Jacobiano:

Na álgebra de vetores em 3 dimensões podemos definir os vetores unitários $\vec{u}_1 = (1, 0, 0)$, $\vec{u}_2 = (0, 1, 0)$ e $\vec{u}_3 = (0, 0, 1)$ de forma que qualquer vetor é escrito como $\vec{V} = V_1\vec{u}_1 + V_2\vec{u}_2 + V_3\vec{u}_3$. Note que os vetores unitários gozam da propriedade de que $\|\vec{u}\| = 1$, onde $\|\vec{V}\| = \sqrt{V_1^2 + V_2^2 + V_3^2}$ é a norma do vetor \vec{V} . Também definimos o produto vetorial através da seguinte operação:

$$\vec{A} \times \vec{B} = \det \begin{pmatrix} \vec{u}_1 & \vec{u}_2 & \vec{u}_3 \\ A_1 & A_2 & A_3 \\ B_1 & B_2 & B_3 \end{pmatrix}$$

Sem perda de generalidade podemos colocar o vetor \vec{A} no eixo 1 e o vetor \vec{B} no plano 1-2 através de uma rotação dos eixos. Nesse caso: $\vec{A} = (A, 0, 0) = A\vec{u}_1$, onde $A = \|\vec{A}\|$. Se o vetor \vec{B} faz um ângulo θ com o vetor \vec{A} então $\vec{B} = (B \cos \theta, B \sin \theta, 0)$ com $B = \|\vec{B}\|$. Colocando esses dois vetores no produto vetorial temos que :

$$\vec{A} \times \vec{B} = \det \begin{pmatrix} \vec{u}_1 & \vec{u}_2 & \vec{u}_3 \\ A & 0 & 0 \\ B \cos \theta & B \sin \theta & 0 \end{pmatrix} = \vec{u}_3 \begin{pmatrix} A & 0 \\ B \cos \theta & B \sin \theta \end{pmatrix} = AB \sin \theta \vec{u}_3$$

Nesse caso $\|\vec{A} \times \vec{B}\| = AB |\sin \theta|$. Agora note que a área de um paralelepípedo composto pelos vetores \vec{A} e \vec{B} é dada pela base que vale A multiplicada pela altura que vale $B |\sin \theta|$. Ou seja $\|\vec{A} \times \vec{B}\|$ é a área do paralelepípedo entre os dois vetores.

Agora vamos tomar o caso em que $\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x(u, w) \\ y(u, w) \end{pmatrix}$. No plano $u - w$ a posição $\begin{pmatrix} u_o \\ w_o \end{pmatrix}$ é transferida para o plano $x - y$ para a posição $\begin{pmatrix} x_o \\ y_o \end{pmatrix} = \begin{pmatrix} x(u_o, w_o) \\ y(u_o, w_o) \end{pmatrix}$. O vetor posição \vec{r} é dado por:

$$\vec{r}(u, w) = x(u, w)\vec{u}_1 + y(u, w)\vec{u}_2.$$

Assim

$$\begin{aligned}\overrightarrow{\delta r_u} &= x(u_o + \delta u, w_o)\vec{u}_1 + y(u_o + \delta u, w_o)\vec{u}_2 - x(u_o, w_o)\vec{u}_1 - y(u_o, w_o)\vec{u}_2 = \\ &= [x(u_o + \delta u, w_o) - x(u_o, w_o)]\vec{u}_1 + [y(u_o + \delta u, w_o) - y(u_o, w_o)]\vec{u}_2 = \\ &= \left[\frac{x(u_o + \delta u, w_o) - x(u_o, w_o)}{\delta u} \right] \delta u \vec{u}_1 + \left[\frac{y(u_o + \delta u, w_o) - y(u_o, w_o)}{\delta u} \right] \delta u \vec{u}_2\end{aligned}$$

$$\text{Ou seja } \overrightarrow{\delta r_u} = \frac{\partial x}{\partial u} \delta u \vec{u}_1 + \frac{\partial y}{\partial u} \delta u \vec{u}_2.$$

$$\begin{aligned}\overrightarrow{\delta r_w} &= x(u_o, w_o + \delta w)\vec{u}_1 + y(u_o, w_o + \delta w)\vec{u}_2 - x(u_o, w_o)\vec{u}_1 - y(u_o, w_o)\vec{u}_2 = \\ \text{Já} &= [x(u_o, w_o + \delta w) - x(u_o, w_o)]\vec{u}_1 + [y(u_o, w_o + \delta w) - y(u_o, w_o)]\vec{u}_2 = \\ &= \left[\frac{x(u_o, w_o + \delta w) - x(u_o, w_o)}{\delta w} \right] \delta w \vec{u}_1 + \left[\frac{y(u_o, w_o + \delta w) - y(u_o, w_o)}{\delta w} \right] \delta w \vec{u}_2\end{aligned}$$

$$\text{Ou seja } \overrightarrow{\delta r_w} = \frac{\partial x}{\partial w} \delta w \vec{u}_1 + \frac{\partial y}{\partial w} \delta w \vec{u}_2.$$

A	área	entre	eles	será
$\ \overrightarrow{\delta r_u} \times \overrightarrow{\delta r_w}\ = \left\ \det \begin{pmatrix} \vec{u}_1 & \vec{u}_2 & \vec{u}_3 \\ \frac{\partial x}{\partial u} \delta u & \frac{\partial y}{\partial u} \delta u & 0 \\ \frac{\partial x}{\partial w} \delta w & \frac{\partial y}{\partial w} \delta w & 0 \end{pmatrix} \right\ = \left\ \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial y}{\partial u} \\ \frac{\partial x}{\partial w} & \frac{\partial y}{\partial w} \end{pmatrix} \delta u \delta w \vec{u}_3 \right\ = \left \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial y}{\partial u} \\ \frac{\partial x}{\partial w} & \frac{\partial y}{\partial w} \end{pmatrix} \right \delta u \delta w$				

Que nos leva ao elemento de área:

$$dxdy = \left| \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial y}{\partial u} \\ \frac{\partial x}{\partial w} & \frac{\partial y}{\partial w} \end{pmatrix} \right| dudw$$

Apêndice XX: Teorema da convolução:

Sejam $\varphi_x(t) = \int_{-\infty}^{+\infty} e^{itx} f_x(x) dx$ e $\varphi_y(t) = \int_{-\infty}^{+\infty} e^{ity} f_y(y) dy$ e suas transformadas inversas

$f_x(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-itx} \varphi_x(t) dt$ e $f_y(y) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-ity} \varphi_y(t) dt$. A convolução é dada por

$$f_x * f_y = \int_{-\infty}^{+\infty} f_x(x-y) f_y(y) dy = \int_{-\infty}^{+\infty} f_y(y) \left[\frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-it(x-y)} \varphi_x(t) dt \right] dy = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \left[e^{ity} f_y(y) dy \right] e^{-itx} \varphi_x(t) dt$$

logo $f_x * f_y = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-itx} \varphi_y(t) \varphi_x(t) dt = FT^{-1}[\varphi_x(t) \varphi_y(t)]$. Aplicando a transformada de ambos os lados

obtemos que $FT[f_x * f_y] = \varphi_x(t) \varphi_y(t)$, ou seja, $\varphi_z(t) = \varphi_x(t) \varphi_y(t)$, a função característica da variável z é o produto das funções características das variáveis x e y . O teorema também vale na transformada inversa $FT^{-1}[\varphi_x * \varphi_y] = f_x(x) f_y(x)$, ou seja, $\varphi_x * \varphi_y = FT[f_x(x) f_y(x)]$.

Generalização do Teorema da Convolução

Uma forma muito elegante de demonstrar o teorema da convolução generalizado é através das funções delta de Dirac. Vamos somar n v.a.s independentes e queremos a densidade de probabilidade da variável $z = x_1 + x_2 + \dots + x_n$. Nesse caso temos:

$$f(z) dz = \iiint_{z < \sum x_i \leq z + dz} \dots \int f_1(x_1) f_2(x_2) \dots f_n(x_n) dx_1 dx_2 \dots dx_n$$

Em vez de colocar a restrição nos limites das integrais, o que nos levaria a um hiper plano de n dimensões, vamos introduzir uma delta de Dirac na integral que nos garanta a igualdade $\sum x_i = z$, ou seja, $\delta[\sum x_i - z] dz$, para a desigualdade $z < \sum x_i \leq z + dz$. Incluindo a delta de Dirac na integral temos:

$$f(z) dz = dz \int_{-\infty}^{+\infty} \dots \int f_1(x_1) f_2(x_2) \dots f_n(x_n) \delta[\sum x_i - z] dx_1 dx_2 \dots dx_n$$

Agora a delta permitiu liberar os limites de integração. Usando $\delta[\sum x_i - z] = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{i(\sum x_i - z)t} dt$ obtemos

$$f(z) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-izt} dt \left\{ \int_{-\infty}^{+\infty} f_1(x_1) e^{ix_1 t} dx_1 \right\} \left\{ \int_{-\infty}^{+\infty} f_2(x_2) e^{ix_2 t} dx_2 \right\} \cdots \left\{ \int_{-\infty}^{+\infty} f_n(x_n) e^{ix_n t} dx_n \right\}$$

$$\text{Ou } f(z) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \varphi_1(t) \varphi_2(t) \cdots \varphi_n(t) e^{-izt} dt$$

Aplicando a transformada de Fourier de ambos os lados temos que $\varphi_z(t) = \varphi_1(t) \varphi_2(t) \cdots \varphi_n(t)$.

Um Teorema para a Correlação:

Note que $(f \otimes g) dz = \iint_{z < x-y \leq z+dz} f(x) g(y) dx dy = dz \int_{-\infty}^{+\infty} f(x) g(x-z) dx$ gera a correlação

$f \otimes g = \int_{-\infty}^{+\infty} f(x) g(x-z) dx$. Por outro lado, podemos usar a delta de Dirac para liberar os limites de

integração $(f \otimes g) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x) g(y) \delta(x-y-z) dx dy$. Usando novamente a delta da forma

$\delta[x-y-z] = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{i(x-y-z)t} dt$ chegamos a $f \otimes g = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-izt} dt \int_{-\infty}^{+\infty} f(x) e^{ixt} dx \int_{-\infty}^{+\infty} g(y) e^{-iyt} dy$. Na integral

de y trocar de variável para $-y$ e ficamos com $f \otimes g = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{-izt} dt FT[f(x)] \times FT[g(-y)]$ onde

$FT[g(-y)] = \int_{-\infty}^{+\infty} g(-y) e^{iyt} dy$. Assim, $f \otimes g = FT^{-1}[FT[f(x)] \times FT[g(-y)]]$, ou aplicando a

transformada de Fourier de ambos os lados $FT[f \otimes g] = FT[f(x)] \times FT[g(-y)]$.